

CURSO SUPERIOR DE ENGENHARIA DE COMPUTAÇÃO

PATRICK PRONOBI RODRIGUES

REDE NEURAL CONVOLUCIONAL APLICADA NO RECONHECIMENTO DE EXPRESSÕES FACIAIS HUMANAS

Caxias do Sul

2018

PATRICK PRONOBI RODRIGUES

REDE NEURAL CONVOLUCIONAL APLICADA NO RECONHECIMENTO DE EXPRESSÕES FACIAIS HUMANAS

Trabalho apresentado para o Curso de Engenharia de Computação, do Centro Universitário Uniftec, como parte dos requisitos para avaliação da unidade curricular de TCC.

Orientador: Dr. João Luis Tavares da Silva

Caxias do Sul

2018

PATRICK PRONOBI RODRIGUES

REDE NEURAL CONVOLUCIONAL APLICADA NO RECONHECIMENTO DE EXPRESSÕES FACIAIS HUMANAS

Trabalho apresentado para o Curso de Engenharia de Computação, do Centro Universitário Uniftec, como parte dos requisitos para avaliação da unidade curricular de TCC.

Aprovado em: 13 de julho de 2018.

BANCA EXAMINADORA

Professor Orientador: Dr. João Luis Tavares da Silva

Professor Avaliador: Dr. Alexandre Moretto Ribeiro

Professor Avaliador: MSc. Daniel da Silva Cotrim

Professor Avaliador: MSc. Neiva Larisane Kuyven

Caxias do Sul
2018

REDE NEURAL CONVOLUCIONAL APLICADA NO RECONHECIMENTO DE EXPRESSÕES FACIAIS HUMANAS

Nome do aluno

Patrick Pronobi Rodrigues

patrickprodrigues@hotmail.com

Nome do professor

Orientador: Dr. João Luís Tavares da Silva

joaoluis.tavares@gmail.com

Resumo: As expressões faciais desempenham um importante papel na representação de informações relevantes sobre os indivíduos, sendo capazes de demonstrar seus sentimentos, vontades e características de comportamento. Microexpressões são movimentos faciais involuntários e breves, que podem ser usados na detecção de fraudes ou sentimentos inconsistentes. Porém, detectar microexpressões é um processo complexo, devido à sua baixa amplitude e curta duração. Este trabalho propõe um método de detecção de macroexpressões e microexpressões faciais, usando uma câmera de alta velocidade e uma rede neural convolucional. A câmera de alta velocidade captura os detalhes sutis das expressões, que são então analisados pela rede. Redes neurais convolucionais possuem uma grande capacidade de reconhecimento de padrões em sinais complexos, o que proporciona a identificação de entradas ricas em detalhes, como as expressões faciais. A rede neural foi treinada com *datasets* de macroexpressões, e para a identificação das microexpressões utilizou-se o quesito de duração do movimento da expressão. Os experimentos demonstraram a possibilidade da detecção das expressões faciais e microexpressões em video.

Palavras-chave: Redes neurais convolucionais. Expressões faciais. Reconhecimento de expressões faciais.

CONVOLUTIONAL NEURAL NETWORK APPLIED IN THE RECOGNITION OF HUMAN FACIAL EXPRESSIONS

Student's Name

Patrick Pronobi Rodrigues

patrickprodrigues@hotmail.com

Teacher's Name

Advisor: Dr. João Luís Tavares da Silva

joaoluis.tavares@gmail.com

Abstract: Facial expressions have an important role in representing relevant information about individuals, such as being able to demonstrate their feelings, wishes and behavior characteristics. Microexpressions are involuntary and brief facial movements that can be used to detect fraud or inconsistent feelings. However, detecting a microexpression is a complex process due to its low amplitude and short duration. This work proposes a method to detect facial macroexpressions and microexpressions, using a high speed camera and a convolutional neural network. The high-speed camera captures the subtle details of the expressions, which are then analyzed by the network. Convolutional neural networks have the ability to recognize patterns in complex signals, which provides the identification of rich inputs, such as facial expressions, in detail. The neural network was trained with datasets of macroexpressions, and the duration of expression movement was used for the microexpressions identification. The experiments demonstrated the possibility of facial expression and microexpression detection in video.

Keywords: Convolutional neural networks. Facial expressions. Facial expressions recognition.

LISTA DE ILUSTRAÇÕES

Figura 1 – Expressão de surpresa 18
Figura 2 – Expressão de medo 19
Figura 3 – Expressão de nojo 21
Figura 4 – Expressão de raiva 22
Figura 5 – Expressão de felicidade 23
Figura 6 – Expressão de tristeza 25
Figura 7 – Conjunto de microexpressões 26
Figura 8 – *Machine learning* 29
Figura 9 – *Supervised learning* 30
Figura 10 – *Unsupervised learning* 31
Figura 11 – Perceptron 33
Figura 12 – Backpropagation 34
Figura 13 – *Kernel* e matriz de entrada 37
Figura 14 – Exemplo de Convolução 37
Figura 15 – *Stride* 38
Figura 16 – ReLU (*Rectified Linear Unit*) 40
Figura 17 – *Pooling* 40
Figura 18 – Camada totalmente conectada 41
Figura 19 – CPU x GPU 43
Figura 20 – Camada convolucional com TensorFlow 44
Figura 21 – Amostra do *dataset* de lentes gravitacionais 46
Figura 22 – Estrutura da CNN de lentes gravitacionais 47
Figura 23 – Visualização da expressão em tempo real 48
Figura 24 – Análise de expressões com filtro gaussiano 2D 49
Figura 25 – Regiões dos músculos responsáveis pelas expressões faciais 50
Figura 26 – Distribuição de classes do *dataset* 53
Figura 27 – Estrutura da CNN do projeto 54
Figura 28 – Método de criação da CNN do projeto 55
Figura 29 – Yi Cam 56
Figura 30 – Haar Cascade 58
Figura 31 – Vetor de expressões 59

Figura 32 – Identificação das expressões 59
Figura 33 – Fluxograma da identificação de microexpressões 60
Figura 34 – Código de classificação das microexpressões 61
Figura 35 – Identificação em video 62
Figura 36 – *Log* 62
Figura 37 – Previsão da microexpressão 63
Figura 38 – Teste de macroexpressão 1 64
Figura 39 – Teste de macroexpressão 2 65
Figura 40 – Teste de macroexpressão 3 65

LISTA DE TABELAS

Tabela 1 – Resultados do experimento de microexpressão 64
Tabela 2 – Resultados dos experimentos de macroexpressões 65

LISTA DE ABREVIATURAS E SIGLAS

CONVNET	*Convolutional Neural Network*
CUDA	*Compute Unified Device Architecture*
CNN	*Convolutional Neural* Network
CPU	*Central Processing Unit*
DECONVNET	*Deconvolutional Neural Netork*
GPU	*Graphics Processing Unit*
GPGPU	*General Purpose Graphics Processing Unit*
IA	Inteligência artificial
ReLU	*Rectified Linear Unit*

SUMÁRIO

1 INTRODUÇÃO 11
1.1 OBJETIVOS 12
1.1.1 Objetivo geral 12
1.1.2 Objetivos específicos 12
1.2 ESTRUTURA DO TRABALHO 13

2 REFERENCIAL TEÓRICO 14
2.1 EXPRESSÕES FACIAIS 14
2.1.1 Representação das expressões faciais humanas 15
2.1.1.1 Expressão de Surpresa 16
2.1.1.1.1 Identificação Estrutural 17
2.1.1.2 Expressão de Medo 18
2.1.1.2.1 Identificação Estrutural 19
2.1.1.3 Expressão de Nojo 20
2.1.1.3.1 Identificação Estrutural 20
2.1.1.4 Expressão de Raiva 21
2.1.1.4.1 Identificação Estrutural 22
2.1.1.5 Expressão de Felicidade 22
2.1.1.5.1 Identificação Estrutural 23
2.1.1.6 Expressão de Tristeza 24
2.1.1.6.1 Identificação Estrutural 24
2.1.2 Microexpressões e macroexpressões 25
2.2 APRENDIZADO DE MÁQUINA 26
2.2.1 Redes Neurais 32
2.3 REDES NEURAIS CONVOLUCIONAIS 34
2.3.1 Camada Convolucional 35
2.3.2 Camada de Não Linearidade 39
2.3.3 Camada de *Pooling* 40
2.3.4 Camada Totalmente Conectada 40
2.3.5 TensorFlow 41
2.3.6 Considerações do Capítulo 44

3 TRABALHOS RELACIONADOS 45
3.1 CONSIDERAÇÕES FINAIS 50

4 METODOLOGIA 51

5 DESENVOLVIMENTO E EXPERIMENTOS 52
5.1 *DATASET* 52
5.2 ESTRUTURA DA CNN 53
5.3 CAPTURA DE IMAGENS 56
5.4 IMPLEMENTAÇÃO 56
5.4.1 Escalonamento e identificação facial 57
5.4.2 Identificação de expressões e microexpressões 58
5.5 APRESENTAÇÃO DOS RESULTADOS 61
5.6 EXPERIMENTOS 63
5.7 CONSIDERAÇÕES FINAIS 66

6 CONCLUSÃO 67

Referências 69

1 INTRODUÇÃO

A capacidade de identificar padrões é uma das características que possibilita ao ser humano o desenvolvimento dos mais variados tipos de habilidades, entre elas está o reconhecimento de expressões faciais. Essa é uma capacidade utilizada extensivamente pelos humanos, ao longo de suas vidas. É uma característica que permite a comunicação não verbal entre as pessoas, sendo possível que sentimentos e sensações sejam transmitidos sem o uso de uma palavra sequer (EAGLEMAN, 2012).

Realizar o reconhecimento das expressões faciais, é um fator que pode colaborar no entendimento do estado emocional das pessoas. Visto que existem doenças psíquicas como a depressão e o transtorno de ansiedade, as quais são, silenciosas e a identificação das características dessas doença por meio das expressões faciais, pode ser um importante fator no diagnóstico precoce desse tipo de problema (EKMAN, 1993).

Segundo uma pesquisa realizada pela WHO(*World Health Organization*), no ano de 2015 a depressão afetava em torno 322 milhões de pessoas no mundo. Um valor que cresceu 18,4%, se comparado a pesquisas realizadas em 2005, número esse que tende a crescer ainda mais. Muito disso devido a natureza da sociedade, que tem dificuldade em aceitar transtornos mentais como doenças, algo que acaba tornando ainda mais difícil a procura de ajuda, por quem sofre desse tipo de complicação (WHO, 2017).

Além do diagnóstico de doenças, as expressões faciais podem ser um caminho na antecipação de crimes e até mesmo no auxílio de pessoas em situações de risco. Entretanto identificar expressões faciais mais sutis, pode ser uma tarefa complexa, algo que normalmente necessita de pessoas especializadas no assunto. (EKMAN, 1993). Algo que pode ser facilitado, com a utilização de computadores para tal tarefa, dessa forma a identificação das emoções humanas pode ser empregada de uma forma mais abrangente.

Para a identificação das expressões, podem ser utilizadas técnicas de inteligência artificial, como as redes neurais convolucionais. Com essa classe de algoritmos de IA, os padrões de cada emoção representados na face podem ser classificados e utilizados, para a tomada das devidas ações (CORREA *et al.*, 2016).

As redes neurais convolucionais fazem parte de uma classe de algoritmos, que tem como objetivo proporcionar aos computadores a capacidade de reconhecer

padrões previamente aprendidos. Esse aspecto pode ser utilizada para que uma máquina, identifique os mais variados tipos de características, contidos em sinais digitas, sejam eles simples ou complexos (KARPATHY, 2017).

As expressões faciais possuem padrões de movimentos musculares, que são apresentados pelos seres, quando sentem ou querem demonstrar algo (EKMAN; FRIESEN, 1975). Dessa forma as redes neurais convolucionais podem ser utilizadas, para interpretar os conjuntos de padrões formados em cada expressão facial. Esse aspecto de aprendizado de padrões faciais, por parte de uma máquina, pode representar um aspecto de grande auxílio no entendimento dos sentimentos e desejos humanos (CORREA *et al.*, 2016).

1.1 Objetivos

Nesta sessão serão elucidados o objetivo geral e os objetivos específicos contidos no projeto.

1.1.1 Objetivo geral

O objetivo do presente trabalho é o de realizar um estudo sobre expressões faciais humanas e *machine learning*, desvendando suas características e funcionamentos de uma forma simples e objetiva. Juntamente com o desenvolvimento um protótipo funcional de um software, capaz de realizar o reconhecimento das expressões faciais universais humanas contidas em imagens, utilizando redes neurais convolucionais.

1.1.2 Objetivos específicos

- Estudar as características das expressões faciais humanas.
- Realizar uma pesquisa sobre as técnicas de aprendizado de máquina, com foco no aprendizado supervisionado.
- Desenvolver um protótipo, utilizando uma rede neural convolucional, para identificar expressões faciais humanas.
- Diferenciar macroexpressões e microexpressões em video, através de testes via quesito de duração da expressão.

1.2 Estrutura do trabalho

O presente trabalho é dividido em 8 capítulos, os quais tem seu conteúdo brevemente explicado, nos itens contidos abaixo:

- Capítulo 1 - (Introdução): contém a apresentação básica da ideia motivadora do trabalho.
- Capítulo 2 - (Expressões faciais): capítulo que apresenta os principais conceitos relacionados com as expressões faciais humanas.
- Capítulo 3 - (Aprendizado de máquina): setor do trabalho onde são elucidados os conceitos e técnicas de *machine learning*.
- Capítulo 4 - (Redes neurais convolucionais): parte do trabalho dedicada a explicação do funcionamento de características e implementação de uma CNN.
- Capítulo 5 - (Trabalhos relacionados): espaço onde estão contidos referencias, sobre projetos de grande colaboração para a realização deste trabalho.
- Capítulo 6 - (Desenvolvimento e experimentos): capítulo que demonstra de forma breve e sucinta, as etapas de desenvolvimento e alguns testes realizados durante o projeto.
- Capítulo 7 - (Conclusão): fechamento do trabalho, local onde são compartilhadas as ideias e aprendizados recebidos ao longo do trabalho.

2 REFERENCIAL TEÓRICO

Neste capítulo é apresentada a fundamentação teórica realizada durante a pesquisa, os temas abordados no capítulo são: expressões faciais; microexpressões e macroexpressões; *machine learning*; redes neurais; redes neurais convolucionais.

2.1 Expressões faciais

As expressões faciais são caracterizadas por um conjunto de movimentos distintos realizados pelos músculos localizados na face. Normalmente são utilizadas para transmitir sensações e podem ocorrer tanto de forma voluntária quanto involuntária, sendo acionadas por mecanismos distintos do cérebro. Quando realizadas de forma involuntária são comandadas pela parte inconsciente do cérebro, sendo consideradas expressões faciais universais e inerentes ao ser. Já quando realizadas de forma voluntária, as expressões podem ter um cunho social, variando conforme a localidade e a cultura do povo e não condizendo necessariamente com uma sensação experimentada pelo ser (FREITAS-MAGALHÃES, 2016).

Habitualmente as expressões faciais estão atreladas a interações corporais, sendo usualmente acompanhadas pela fala, gestos e determinadas posturas. A face humana pode reagir a determinadas experiências com uma série de expressões, as quais carregam um sinal que pode ou não ser condizente com o resto das ações tomadas pelo seu corpo. Com a análise dos sinais contidos na expressão facial e corporal do ser humano podem ser tiradas diversas conclusões, desde a determinação de um estado de desconforto ou alegria até a descoberta de um comportamento mentiroso (EKMAN, 1993).

Comumente as demonstrações de sentimentos estão relacionadas a expressões faciais, entretanto existem evidências de pessoas que podem demonstrar sentimentos mesmo sem que existam reações faciais típicas de suas emoções, algo possível de ser observado através de um exame de *eletromiografia*[1]. Dessa forma é possível concluir que em casos específicos as expressões e reações corporais podem vir desacompanhadas de um sentimento concordante. O contrário também é verdadeiro, pois os seres humanos podem demonstrar expressões faciais sem que haja um

[1] Técnica onde são monitoradas as respostas produzidas pelas fibras musculares, quando submetidas a impulsos elétricos (BASMAJIAN; LUCA, 1985)

sentimento correspondente, um bom exemplo para isso é quando alguém posa para uma foto, a expressão e os gestos podem representar um sentimento que não esta sendo propriamente sentido pela pessoa (EKMAN, 1993).

Nas próximas seções serão detalhadas as características, definições e representações das principais expressões faciais humanas. Segundo o trabalho intitulado *unmasking the face*, publicado em 1975 pelos autores: Paul Ekman e Wallace V. Friesen.

2.1.1 Representação das expressões faciais humanas

As emoções humanas podem ser transmitidas por dois tipos de canais, são eles o canal auditório e o visual. Através do canal auditório podem ser levantadas informações sobre a pessoa por meio de suas palavras e voz, já através do canal visual, podemos perceber sua movimentação corporal e suas expressões faciais, as quais podem conter emoções simples ou complexas.

Detectar emoções através de expressões faciais é uma árdua tarefa, pois a face humana pode produzir até três tipos de sinais: estáticos, lentos e rápidos. Cada um desses sinais contém informações distintas, que caso não sejam interpretadas corretamente podem induzir a conclusões erradas sobre a expressão e a possível emoção relacionada.

Os sinais estáticos são formados por características fixas da face humana, como por exemplo: cor da pele, estrutura óssea, posição dos olhos, além de outras características inertes da face. Esse é o tipo de sinal que deve ser analisado quando se busca identificar características físicas, é a indicação que nos permite diferenciar pessoas umas das outras pelo rosto. Já os sinais lentos são caracterizados por: rugas, marcas, textura e outros sinais faciais. Estes são os indícios levados em consideração quando se busca analisar a idade da pessoa, por exemplo.

O **sinal rápido** é geralmente usado para realizar a identificação e a análise de expressões faciais. Nesse tipo de traço são representados os movimentos dos olhos, sobrancelhas, músculos, dentre outros componentes da face. Os sinais rápidos podem acontecer em questão de segundos ou até mesmo frações de segundos.

Os sinais produzidos pelo rosto podem ser mascarados de certa forma, embora para isso seja necessário um certo esforço por parte da pessoa para esconder suas intenções. Os sinais estáticos e os lentos podem ser mascarados com penteados, maquiagem e adornos, já quando se trata de sinais rápidos é possível realizar uma

inibição parcial tentando esconder os movimentos da face ou usando óculos escuros por exemplo.

Em se tratando de reconhecimento de emoções a partir de expressões faciais, falamos em sinais transitórios. Os sinais transitórias ocorrem em movimentos musculares, que provocam alterações visíveis na face, fazendo dessa forma com que aparecem marcas temporárias que altera a posição dos componentes da face. As emoções primarias podem ser caracterizadas por mudanças rápidas da face, podendo ser identificadas através de um mapeamento das características da face. É importante ressaltar que as emoções não são representadas pelos sinais estáticos e lentos, apenas pelos rápidos.

Um aspecto importante na análise de expressões faciais é a identifica se a expressão é realmente uma emoção ou o próprio aspecto da pessoa. Se uma pessoa fica irritada por segundos, minutos ou até horas isso pode ser considerado uma emoção, mas se ela está sempre irritada isso é na verdade seu humor, essa pessoa tem um comportamento irritado.

Além das expressões faciais fundamentais existem diversas outras expressões mais complexas, as quais são formadas com combinações das expressões básicas universais. A expressão de depressão por exemplo é uma combinação da tristeza e medo, quando esse medo é evidenciado pode ser uma expressão de ansiedade, ou seja a análise de expressões combinadas é relativamente mais difícil de ser interpretada.

Os sinais rápidos podem trazer as chamadas **mensagens emblemáticas**, ou seja, mensagens não verbais que demonstram desde cumprimentos não verbais ("oi, tchau"), até indagações e aprovações ou desaprovações. Podem existir também emblemas emocionais, os quais podem representar parcialmente ou totalmente expressões voluntárias. Por exemplo o ato de enrugar o nariz, que é uma das componentes da expressão de nojo, pode ser utilizado como um emblema para transmitir a mensagem de desgosto ou desaprovação para outras pessoas, de forma não verbal.

A seguir serão descritas, de forma sucinta, as características das expressões faciais universais (surpresa, medo, raiva, nojo, alegria, tristeza).

2.1.1.1 Expressão de Surpresa

A surpresa é uma emoção breve e repentina, ou seja se uma pessoa tem tempo para pensar sobre determinado evento antes de fazer uma expressão facial de surpresa, isso significa que ela não esta realmente surpresa. A expressão dessa emoção é

breve, visto que após a surpresa são desencadeadas outras emoções, dessa forma as pessoas não ficam surpresas por muito tempo. É uma expressão desencadeada por situações inesperadas, como por exemplo uma visita não programada de alguém, ou eventos considerados indevidos, que são esperados, mas acontecem de forma diferente.

Existem várias sensações que podem gerar fatores de surpresa, podendo estar entre sons, cheiros, sabores, toques ou até mesmo sensações não físicas. Pode ser desencadeada até mesmo por comentários ou ações incorretamente antecipados. Independente do evento, se a pessoa teve tempo para antecipar corretamente, ela não terá uma sensação de surpresa.

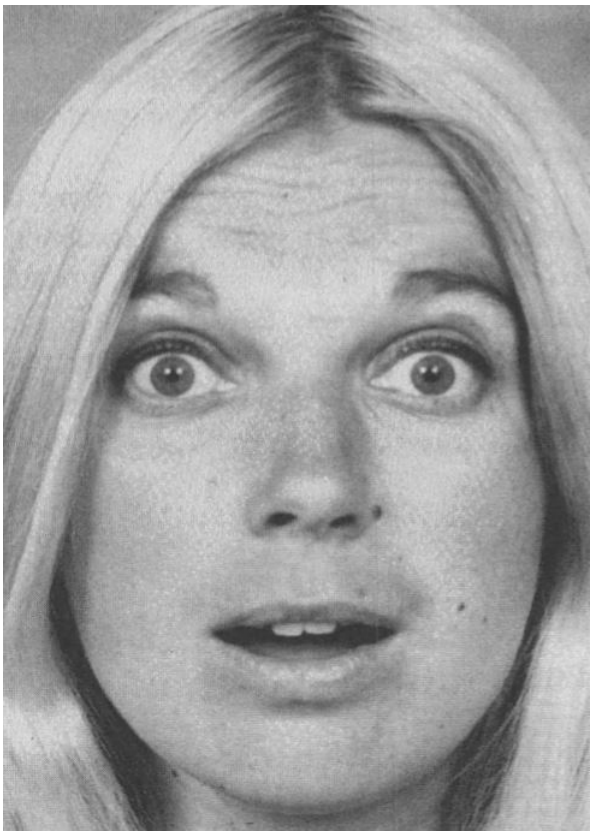
Como a surpresa é um evento breve, geralmente são desencadeadas outras expressões faciais rapidamente, como no caso de uma surpresa feliz, onde rapidamente após a expressão de surpresa se tem inicio uma expressão de felicidade. O medo é uma expressão que comumente acompanha a expressão de surpresa, chegando a ser confundida em certas análises. Como a surpresa é momentânea normalmente é vista como uma mistura da expressão da emoção seguinte.

2.1.1.1.1 Identificação Estrutural

Durante a expressão de surpresa as sobrancelhas ficam levantadas e com uma aparência curvada, a pele abaixo da sobrancelha fica esticada e devido ao seu levantamento aparecem marcas horizontais(rugas) por toda a testa. Os olhos se apresentam bem abertos e com a esclera[2] acima da iris visível, além disso a mandíbula se abre, fazendo com que a boca levemente relaxada se abra também. Não são todas pessoas que apresentam visíveis as marcas de rugas na testa, principalmente crianças, além disso existem pessoas que possuem rugas permanentes na região da testa. Em alguns casos isolados, podem ser observadas características separadas da expressão de surpresa como, somente movimentos oculares ou movimentos de testa e sobrancelha. Além disso podem ser utilizadas inclusive palavras acompanhando a expressão. A Figura 1 ilustra uma face moderada de surpresa, contendo todas as suas características.

[2] Nome científico para a parte branca e fibrosa dos olhos.(CASSIN; RUBIN, 2006)

Figura 1: Expressão de surpresa



Fonte: (EKMAN; FRIESEN, 1975)

2.1.1.2 Expressão de Medo

O medo é um sentimento relacionado a sobrevivência, os seres humanos assim como outros animais, temem a dor, seja ela física ou psicológica. Sobreviver nada mais é do que aprender a escapar de situações que envolvam dor severa ou tragam possibilidades de lesões. Com o passar da vida aprendemos a antecipar os perigos, evitando dessa forma situações potencialmente perigosas.

O sentimento de medo pode ser desencadeado por eventos, pessoas, animais e até mesmo ideias que pareçam perigosas ao olhar de quem esboça a reação. Como o medo é utilizado para antecipar e prevenir situações desagradáveis, em certas ocasiões quando pessoas são injuriadas sem aviso prévio, o medo não é sentido com intensidade, dando lugar a outro sentimento de reação, como por exemplo a raiva àquilo que desencadeou o medo.

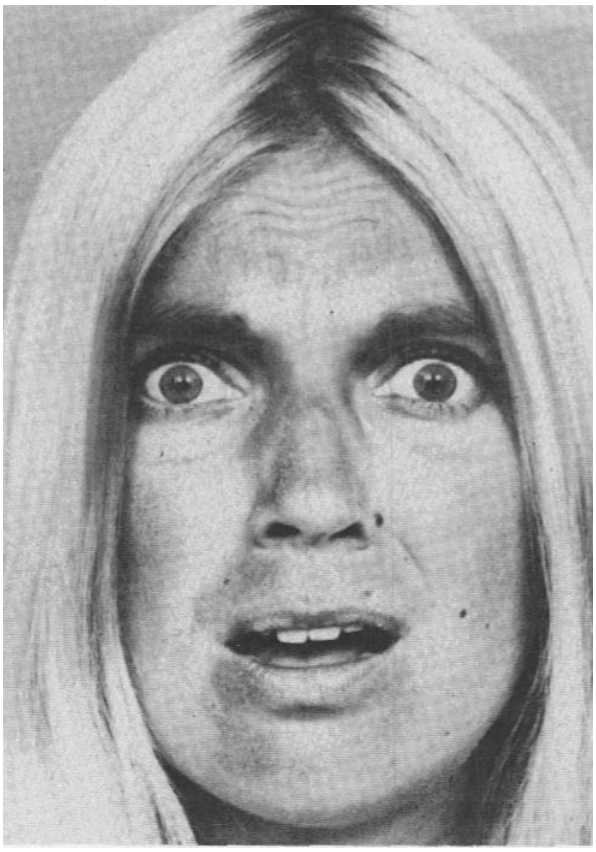
Diferentemente da surpresa que pode ser agradável ou não, o medo gera uma sensação ruim, podendo ser ela leve ou até altamente tóxica para a pessoa, podendo gerar sensações terríveis e traumáticas. Quando muita assustada a pele de uma pessoa pode ficar pálida e altamente molhada de suor, juntamente com isso seus batimentos e

respiração ficam mais acelerados, podendo ainda apresentar enjoos, perda de controle da bexiga e intestino, mãos tremulas e dificuldade de movimentação, em certas vezes ficando até paralisada. É possível ainda que uma pessoa fique com medo por longos perigos e isso é um estado que a deixa exausta, devido a todas as características de extrema tensão dessa emoção.

2.1.1.2.1 Identificação Estrutural

Ao longo da execução da expressão de medo as sobrancelhas ficam altas e alinhadas e um pouco puxadas para o lado interno. Assim como na surpresa, na expressão de medo aparecem também linhas horizontais na face, entretanto essas linhas tipicamente não passam por toda a extensão da testa. Os olhos ficam abertos e tensos, sendo que a pálpebra superior fica levantada e a pálpebra inferior tensa. A boca se apresenta aberta ou entreaberta com os lábios tensos e puxados para trás. A representação da expressão de medo pode ser vista na Figura 2

Figura 2: Expressão de medo



Fonte: (EKMAN; FRIESEN, 1975)

2.1.1.3 Expressão de Nojo

Nojo é um sentimento que representa aversão e desgosto. Pode ser ocasionado por sensações como aromas, gostos e sons desagradáveis ou até mesmo pessoas ou ideias, considerados repulsivos.

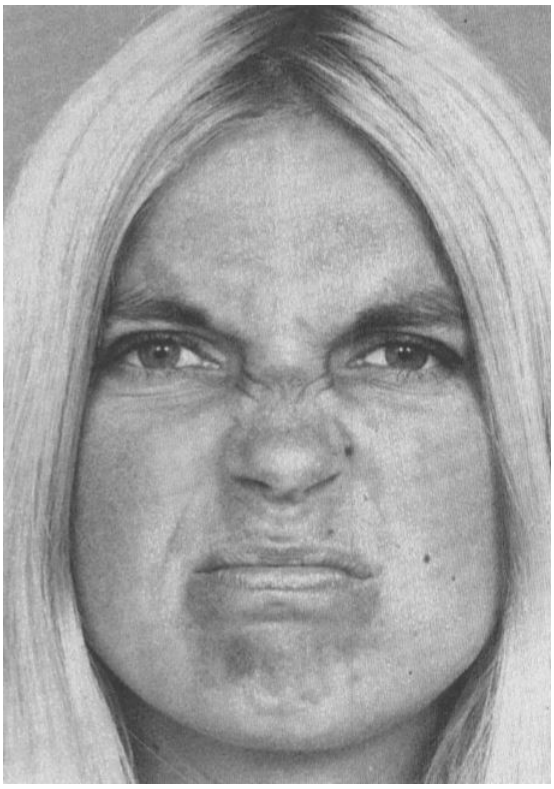
Essa emoção faz com que a pessoa queira sair de perto ou tirar de perto de si o causador do sentimento. O responsável pela causa do nojo pode ser algo subjetivo, pois coisas que dão nojo a uma pessoa não necessariamente trarão a mesma sensação para outra. Existem alguns sentimentos relativos ao nojo, como no caso do desprezo que é uma repulsa direcionada a pessoas e suas ações.

Em certos momentos a raiva pode ser experimentada juntamente com o nojo, uma pessoa pode ter desgosto de algo e após sentir raiva sobre a fonte causadora. Além da raiva o desgosto pode se misturar as outras emoções (medo, tristeza, felicidade, e surpresa).

2.1.1.3.1 Identificação Estrutural

Quando uma pessoa sente desgosto, uma das características mais importantes é a subida do nariz, que acaba ficando enrugado. Juntamente com o nariz o lábio superior, inferior e as bochechas tem a tendência de subir, já a testa é levemente baixada. A Figura 3 representa uma expressão facial completa de nojo.

Figura 3: Expressão de nojo



Fonte: (EKMAN; FRIESEN, 1975)

2.1.1.4 Expressão de Raiva

A raiva é uma emoção perigosa, pois quando estamos com esse sentimento somos mais propensos a colocar outras pessoas em situações de risco, podendo inclusive ocasionar perdas de controle.

Inúmeros eventos podem resultar em sensações de raiva. Geralmente quando as pessoas se sentem frustradas tendem a ter reações agressivas, essa frustração pode ser originada tanto por fontes ligadas a pessoas, quanto a objetos ou causas naturais. Ocasiões que apresentem ameaças físicas, ou até mesmo psicológicas podem ocasionar reações de raiva, assim como coisas que desagradem determinados valores morais. Problemas com atingir expectativas podem gerar raiva, assim como a própria reação à raiva de outra pessoa. Ou seja muitas causas que podem diferir dependendo de como a pessoa interpreta ou enxerga os acontecimentos ao seu redor.

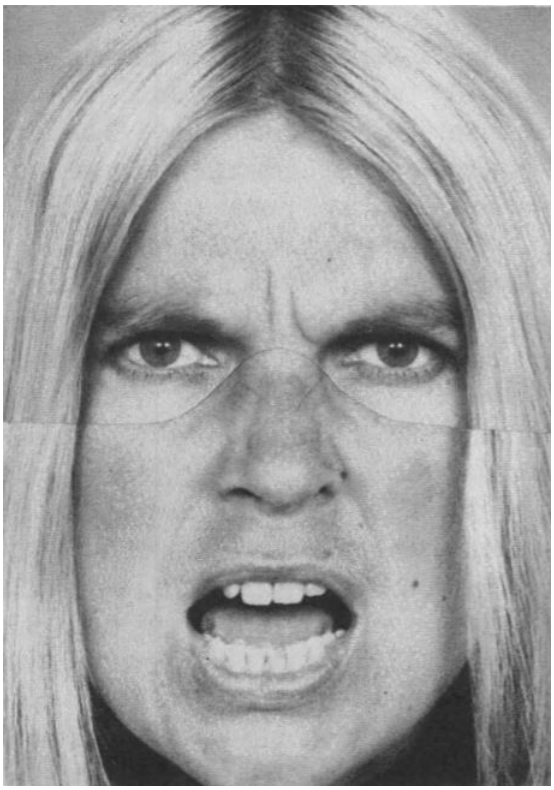
Em situações de raiva a pressão sanguínea e o fluxo respiratório aumentam, o corpo tende a ficar mais ereto e os músculos tensos, podendo existir também uma leve inclinação em direção a fonte causadora da raiva. Quando em raiva intensa é praticamente impossível que uma pessoa fique totalmente parada, pois está preparada

literalmente para atacar, por isso a raiva pode ser considerada uma emoção relacionada a própria defesa.

2.1.1.4.1 Identificação Estrutural

Durante a expressão de raiva as sobrancelhas ficam baixas e próximas, assim como aparecem linhas verticais entre as duas sobrancelhas. As pálpebras ficam tensas e os olhos podem ficar um pouco protuberantes. Já os lábios podem assumir tanto uma posição aberta e tensa, ou ficarem firmemente unidos, além disso as narinas podem sofrer uma certa dilatação, facilitando assim a passagem de oxigênio. A expressão facial de raiva pode ser vista na Figura 4.

Figura 4: Expressão de raiva



Fonte: (EKMAN; FRIESEN, 1975)

2.1.1.5 Expressão de Felicidade

A felicidade é um sentimento relacionado a boas experiências e situações. Diferentemente das emoções de raiva, medo, nojo e tristeza que são emoções negativas, a felicidade proporciona uma sensação positiva. Assim como outras emoções a felicidade pode ser proporcionada por situações psicológicas ou físicas. Em certos

casos a felicidade pode ser confundida com prazer ou excitação, no entanto essas duas sensações são experiências distintas que envolvem felicidade.

Existem diversos eventos que podem incitar sensações felizes, entre eles estão: sentimentos ruins que deixam de ser sentidos; sensações de desconforto; vontade de ir ao banheiro ou até fome e sede; além disso dores ou outros tipos de incômodos físicos e até mesmo emoções negativas (raiva, medo, tristeza, nojo).

2.1.1.5.1 Identificação Estrutural

Da mesma forma que outras expressões, a felicidade possui níveis de intensidade, as quais possuem a posição dos lábios como um fator determinante. Quando uma pessoa está se sentindo feliz seus lábios tem os cantos puxados para trás e para cima, podendo também ficar levemente ou bem abertos, dependendo da intensidade do sentimento. Pode ser vista também uma espécie de dobra na pele entre a região do nariz e das extremidades dos lábios, assim como um levantamento nas bochechas. Além disso as pálpebras inferiores ficam levemente levantadas e em alguns casos podem aparecer rugas nos cantos externos dos olhos. A expressão de felicidade moderada pode ser vista na Figura 5.

Figura 5: Expressão de felicidade



Fonte: (EKMAN; FRIESEN, 1975)

2.1.1.6 Expressão de Tristeza

"Na tristeza seu sofrimento é silencioso"(EKMAN, 1993). Quando tristes as pessoas não gritam ou choram alto, apenas sofrem em silêncio. A tristeza pode ser encadeada por inúmeros fatores, entretanto um dos mais marcantes é a sensação da perda. Essa emoção raramente é breve, podendo durar horas e até mesmo dias.

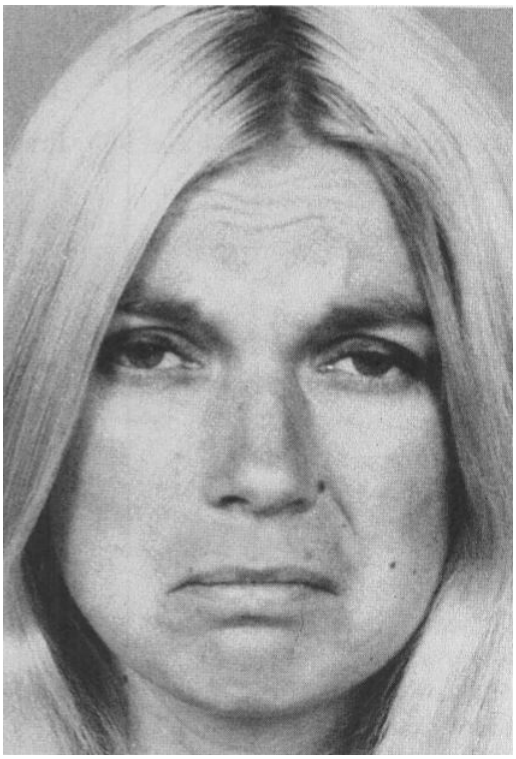
A tristeza não é um sentimento ativo e sim passivo, essa emoção não traz consigo a dor física, seu sofrimento é psicológico. A tristeza não é necessariamente um sentimento imediato, uma pessoa pode ficar triste até mesmo por um acontecimento ocorrido há anos. Normalmente o choro e a reclamação são reações que acompanham a tristeza, entretanto sentimentos como a raiva podem acabar por mascarar algumas dessas características.

Assim como os outros sentimentos a tristeza possui diversas intensidades, que variam desde sensações de desânimo até sentimentos severos como os ocasionadas pela perda de alguém querido. Além disso a tristeza pode também servir para desencadear sentimentos como a raiva, nojo e até mesmo algumas sensações de felicidade, ocasionadas por lembranças ou desejos.

2.1.1.6.1 Identificação Estrutural

A aparência da tristeza quando sentida em sua forma mais leve, pode ser difícil de ser identificada, pois pode não haver nenhum fator marcante na face além do rosto relaxado aparentando perda de tônus muscular. A expressão completa de tristeza é caracterizada por sobrancelhas com cantos internos alinhados, assim como cantos interno das pálpebras superiores levantados, juntamente com lábios para baixo e até mesmo tremendo. Além disso, a pele abaixo da sobrancelha fica com uma aparência de triangulo, com o canto interno para cima. A expressão completa de tristeza pode ser vista na figura 6.

Figura 6: Expressão de tristeza



Fonte: (EKMAN; FRIESEN, 1975)

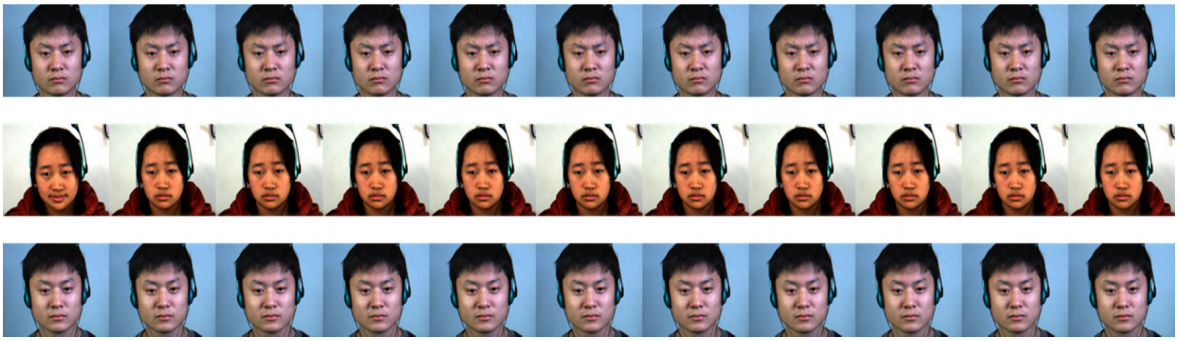
2.1.2 Microexpressões e macroexpressões

Expressões faciais são mais do que simples movimentos localizados no rosto, pois podem carregar consigo inúmeros significados, dos mais simples como o humor do dia até os mais complexos como dúvidas sobre a vida e o universo. As expressões faciais podem ser divididas em dois grupos, macroexpressões e microexpressões. A análise destas expressões leva em consideração vários atributos: amplitude, assimetria, duração, movimentos iniciais, deslocamento, intensidade e movimentação da cabeça. Entretanto, quando se trata de microexpressões o fator de duração torna-se um dos mais importantes, visto que essa classe de expressões acontece em instantes muito rápidos de tempo. Microexpressões são involuntárias e normalmente são apresentadas quando uma pessoa tenta esconder sua real emoção ou vontade. Os movimentos podem ser sutis como olhos piscando e desvios de olhar, ou até mesmo mais abruptos como movimentos de cabeça e boca (RAMACHANDRAN, 1994).

Uma macroexpressão pode durar entre 1/2 à 4 segundos tipicamente, podendo em certas ocasiões durar minutos ou horas. Já uma microexpressão tem sua duração contida entre 1/15 e 1/5 segundos, sendo algo breve, normalmente involuntário e difícil de ser identificado. Geralmente as microexpressões tem suas características em torno

apenas das 6 expressões faciais universais, podendo apresentar características parciais dessas expressões. Isso acontece por exemplo, quando a pessoa tenta esconder sua real emoção, não conseguindo de forma plena e acaba deixando escapar uma característica de sua real emoção, de forma involuntária (RAMACHANDRAN, 1994). Na figura 7, pode-se visualizar as sequências de *frames* que representam microexpressões. Na primeira coluna é visto um exemplo negativo de microexpressão, na segunda um exemplo positivo e na terceira, uma microexpressão de surpresa é presenciada (BORZA *et al.*, 2017).

Figura 7: Conjunto de microexpressões



Fonte: (BORZA *et al.*, 2017)

Para os fins da pesquisa e desenvolvimento realizado no trabalho, **serão consideradas válidas como microexpressões, apenas as macroexpressões executadas no intervalo de 1/15 a 1/5 de segundos**. Dessa forma o algoritmo de detecção e a metodologia da câmera de alta velocidade podem ser testados, sem esbarrar nas dificuldades da obtenção de um *dataset* especializado em microexpressões faciais.

2.2 Aprendizado de Máquina

A aprendizagem é um fenômeno que engloba a aquisição de novos conhecimentos e habilidades cognitivas, assim como a reprodução e verificação desses conhecimentos. Representar essa característica inerente aos humanos em computadores é uma das tarefas mais desafiadoras e fascinantes, das quais as técnicas de inteligência artificial buscam estudar e reproduzir (MITCHELL, 1997).

O aprendizado de máquina faz parte do estudo da inteligência artificial, onde as bases do pensamento racional foram estabelecidos centenas de anos atrás, na filosofia, quando Aristóteles (384-322 a.C.) resolveu formular um conjunto de leis que governam a racionalidade humana. Aristóteles desenvolveu um sistema informal de silogismos o

qual permitia gerar conclusões mecanicamente de acordo com as premissas iniciais. Esse foi apenas o inicio do compreensão da maneira como formamos e entendemos os acontecimentos ao nosso redor (RUSSELL; NORVIG, 2009).

Ao longo de décadas a inteligência artificial foi se desenvolvendo com a ajuda de cientistas de várias áreas, entre elas: Filosofia, Matemática, Psicologia, Neurociências. Contudo a IA ainda era algo que não possuía muita ligação com os computadores digitais. O matemático britânico Alan Turing foi um dos primeiros a tratar sobre esse tema em 1950 com a publicação da obra *Computing Machinery and Intelligence*. Turing indagou se uma máquina seria capaz de pensar como um ser humano, lançando assim as primeiras bases para o que viria a ser a IA. Esse pode ser considerado o processo que deu inicio a inteligência artificial a qual conhecemos hoje (LUGER, 2008).

Através do "jogo da imitação", desenvolvido por Turing, foi estabelecida uma métrica para a classificação de máquinas inteligentes, a qual não é muito utilizada nos dias de hoje, pois o jogo da imitação buscava características de inteligência humana nos computadores e não fatores como capacidades matemáticas, por exemplo (LUGER, 2008).

A área da inteligência artificial que busca reproduzir os processos de aprendizado nos computadores, é chamada de *Machine Learning*. Teve suas pesquisas iniciadas na década de 80, com a motivação de utilizar a IA para tornar os programas de computadores capazes de se aperfeiçoarem com suas próprias experiências. Essa tecnologia é desenvolvida levando em consideração fatores estatísticos, cognitivos, filosóficos e biológicos. Sua implementação busca tornar os computadores capazes de desenvolverem características que não são explicitamente escritas em sua programação, tornando-os assim capazes de resolverem problemas complexos e que dificilmente são solucionados por algoritmos tradicionais (LANGLEY, 2011).

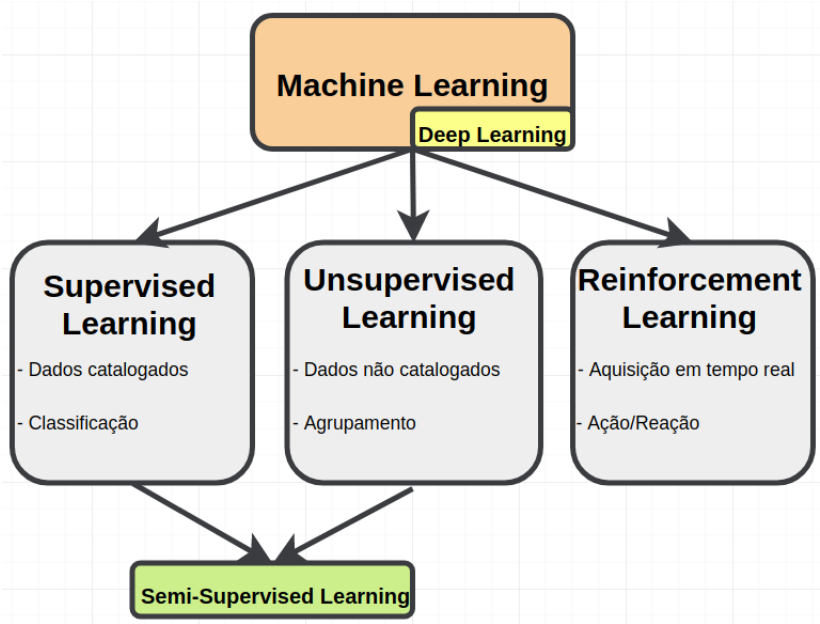
A capacidade de aprender é uma característica que deve obrigatoriamente fazer parte em qualquer sistema realmente inteligente. Na computação existem diferentes abordagens para o aprendizado, cada uma focada em diferentes premissas, que buscam representar a tomada de decisões de forma inteligente pelos computadores. Para que essa característica seja implementada nas máquinas, existem diferentes metodologias que podem ser utilizadas, cada uma com um foco diferente de representação do aprendizado. Passamos a enumerar algumas delas segundo a referência de (LUGER, 2008):

- *Conexionista*: biologicamente inspirada no cérebro humano e animal, nesse tipo de abordagem são utilizadas redes de processamento divididas em unidades simples chamadas de neurônios artificiais. O aprendizado acontece quando a cada interação as redes ajustam seus pesos e estruturas. Após os ajustes necessários a solução é dada pelo conjunto de neurônios na rede, onde cada um contribui com uma porção do resultado;
- *Emergente*: assim como a abordagem conexionista, possui inspiração biológica, mais especificamente da genética evolucionária. Um exemplo são os algoritmos genéticos, os quais a solução dos problemas é estabelecida através de mutações dos seus dados de entrada, as amostras geradas através de cada mutação são testadas e reproduzidas para que a cada nova geração os descendentes possuam melhorias em comparação as gerações anteriores;
- *Simbólica*: o aprendizado funciona com a modificação de sua base de conhecimento, ou seja os seus símbolos, que refletem diretamente na execução do programa. Diferentemente da abordagem conexionista, que modifica sua estrutura durante o aprendizado, o modelo simbólico modifica apenas a sua base de dados para obter resultados diferentes;
- *Probabilística*: utilizada para a resolução de problemas ainda não totalmente entendidos pelos seres humanos, esse método estabelece ligações entre eventos aprendidos anteriores, com acontecimentos atuais. Dessa forma é possível prever a probabilidade de um acontecimento ser verdadeiro com base nos dados de outros acontecimentos. Alguns exemplos do uso do aprendizado probabilístico são as regras de Bayes e os modelos de Markov.

Os algoritmos de *Machine Learning* normalmente são divididos em quatro grupos, separados de acordo com seus propósitos e características, que devem ser analisadas corretamente para responder de forma mais efetiva ao problema que se deseja solucionar. Os tipos de algoritmos de Machine Learning podem ser classificados em: *Supervised Learning*; *Unsupervised Learning*; *Semi-Supervised Learning*; *Reinforcemente Learning*. Juntamente com esses grupos existe o conceito de *Deep Learning* (aprendizado profundo), com sua utilização o sistema alvo é divido em camadas, onde cada camada busca reconhecer certas características. A saída resultante de cada camada é enviada como entrada para a próxima, dessa forma o sinal percorre um caminho em profundidade passando por métodos distintos de processamento em cada

camada, o que permite a cada camada usar diferentes funções para reconhecer características distintas, que no final serão responsáveis pelo saída do sistema. A estrutura de divisão das áreas de *Machine Learning* pode ser vista na figura 8 (WITTEN; FRANK; HALL, 2011).

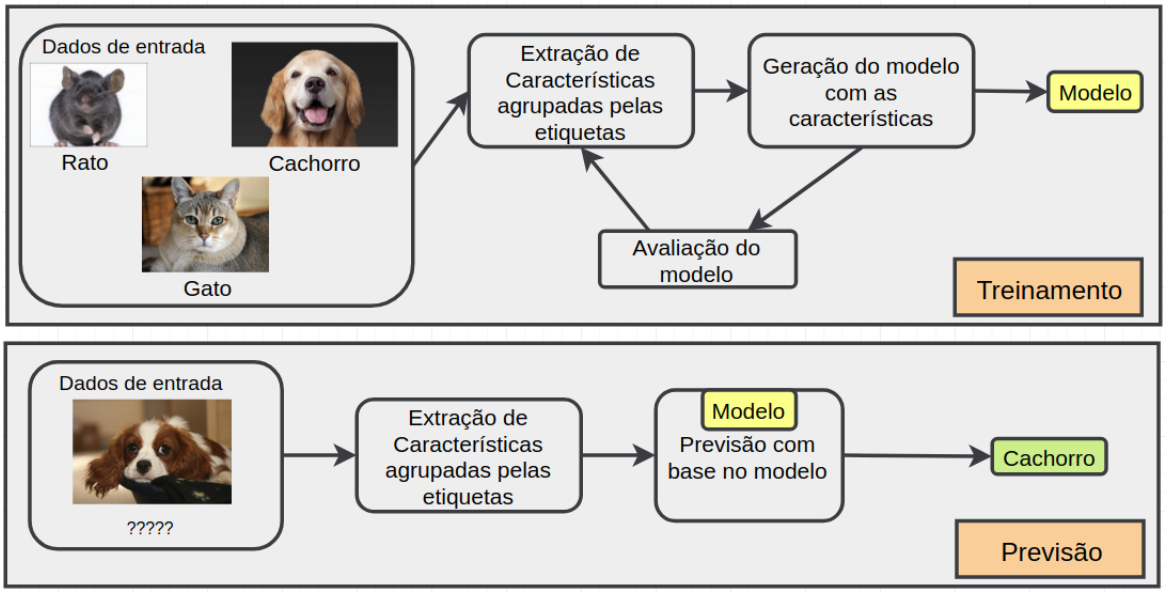
Figura 8: *Machine learning*



Fonte: (AUTOR. 2017)

A técnica de *Supervised Learning* é caracterizada por possuir um conjunto de dados, utilizados como exemplo do que o algoritmo vai analisar. Nessa técnica o algoritmo compara o resultado obtido com os parâmetros contidos nos exemplos e a partir dessa comparação decide o que deve ser modificado para que ocorra a diminuição do erro. Isso é feito de forma matemática, fazendo assim com que alguns parâmetros sejam ajustados para que o resultado seja mais coerente com os valores contidos nos exemplos de treinamento. Essa é uma abordagem para o tratamento de problemas de classificação, quando se possui bases de dados catalogados, como por exemplo na identificação de padrões em imagens, sons ou textos. O grande desafio de se usar *Supervised Learning* é conseguir uma base de dados confiável e com dados suficientes para que a etapa de treinamento tenha resultados satisfatórios. Uma representação possível pode ser vista na figura 9. Os algoritmos que utilizam Redes Neurais, Regressão Linear, Filtro de Bayes e Árvores de Decisão são alguns dos beneficiados por essa técnica de aprendizagem (MøLLER, 1993).

Figura 9: *Supervised learning*

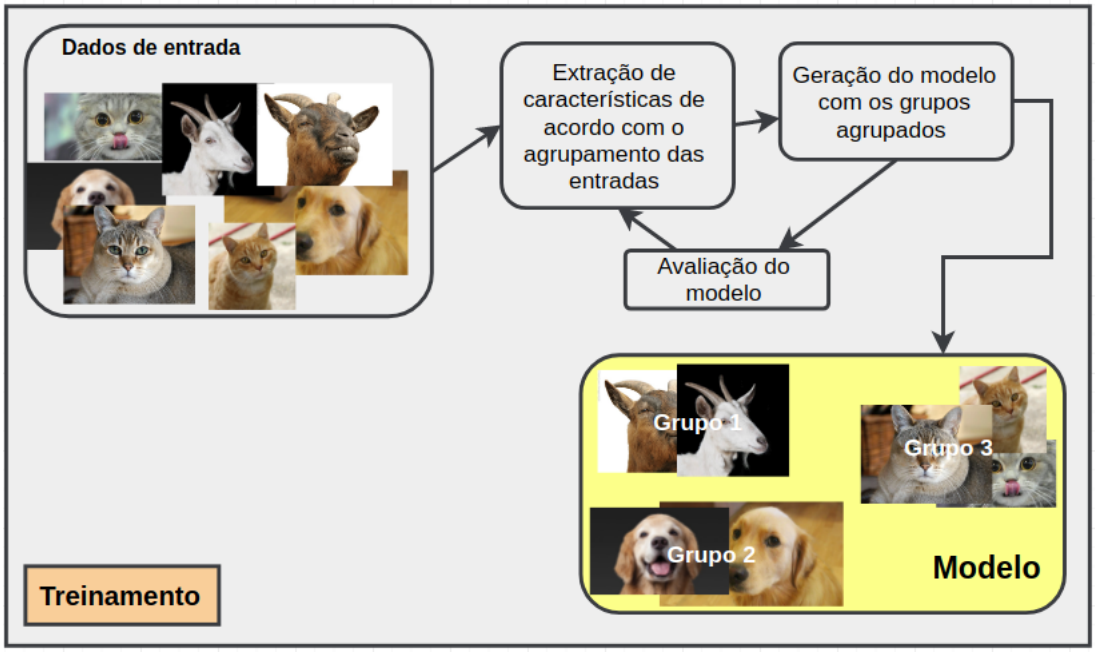


Fonte: (AUTOR. 2017)

Para tentar resolver o problema gerado pela dificuldade na obtenção de dados, pode-se utilizar a técnica de Aprendizagem Não Supervisionada (*Unsupervised Learning*), onde não é necessário que exista uma base de dados inicial catalogada. A parte da supervisão pode ser feita ao final, criando assim rótulos com base nas características que foram encontradas no treinamento. Isso é feito na forma de agrupamentos (*Clusters*), onde o algoritmo agrupa os objetos que possuem características semelhantes. Essa estrutura de funcionamento, pode ser vista na figura 10. O *unsupervised learning* apresenta vantagens no que se diz respeito a obtenção dos dados iniciais, pois não é necessário que se possua uma grande base de dados rotulada para que o treinamento seja iniciado. Um dos algoritmos que utiliza essa abordagem é o *K-means*[3], muito utilizado na mineração de dados (SANGER, 1989).

[3] Proposto por J. MacQueen em 1967, o algoritmo de Análise de Agrupamento k-means é um método de *Clustering* que determina o particionamento ideal de um número de observações entre grupos específicos, onde cada observação pertence ao grupo mais próximo da média.

Figura 10: *Unsupervised learning*



Fonte: (AUTOR. 2017)

A técnica de Aprendizagem Semi-supervisionada (*Semi-Supervised Learning*) surgiu como uma mescla do método supervisionado com o método não-supervisionado, para ser utilizado na resolução de problemas que possuem poucos dados rotulados. Para que o algoritmo seja treinado, são fornecidos grupos de dados rotulados e grupos de dados não rotulados. A vantagem dessa utilização é unir o melhor das duas metodologias, pois conseguir dados não catalogados é muito mais fácil, mas a precisão do sistema é muito maior quando o treinamento é feito com dados catalogados. Entretanto, esses dados são mais difíceis de serem encontrados e normalmente necessitam de especialistas para a devida análise. Novamente, o algoritmo *K-Means* é bastante utilizado de acordo com essa abordagem (ZHU, 2010).

A abordagem de Aprendizagem por Reforço (*Reinforcement Learning*) é motivada pela necessidade de fazer com que um agente inteligente seja capaz de adaptar-se a ambientes desconhecidos. Cada ação realizada pelo agente é avaliada através de uma *Feedback Function*, recebendo um valor para o esforço utilizado ao realizar a ação, assim como seu fator de recompensa. Durante a etapa de treinamento as ações são realizadas aleatoriamente e seus pesos são analisados. O algoritmo consiste em fazer com que o agente inteligente chegue ate o final do caminho utilizando a trajetória que representa menos esforço e mais recompensa. Ao final do ciclo de treinamento, a tendência é a de que o algoritmo tenha reforçado as melhores rotas possíveis ba-

seados nos resultados obtidos pela *Feedback Function* para cada ação. Esse tipo de abordagem é bastante utilizada em veículos autônomos, onde o carro pode analisar um ambiente desconhecido e determinar qual sera o melhor percurso para ser percorrido (SUTTON; BARTO, 1998).

2.2.1 Redes Neurais

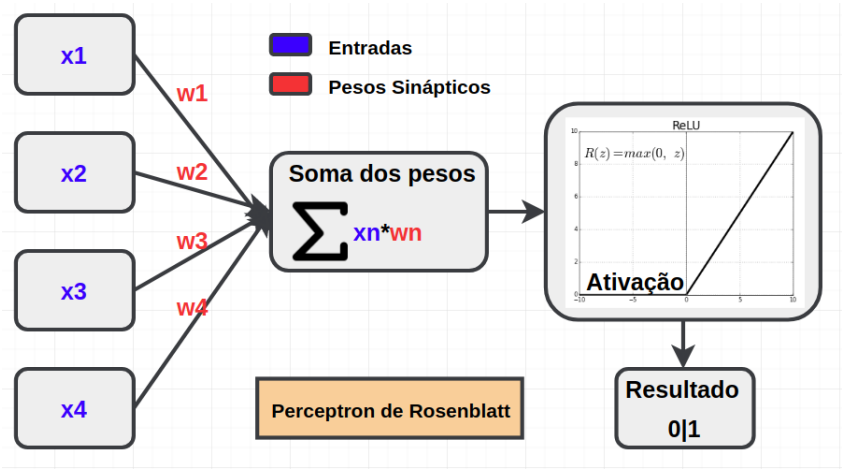
As redes neurais artificiais são estruturas de inteligência artificial da abordagem conexionista, na qual os pesos de sua estrutura são modificados de acordo com seu aprendizado. Sua maneira de assimilar conhecimento se assemelha com a maneira a qual os humanos e animais aprendem, para isso necessitam de exemplos catalogados, que são utilizados para seu treinamento. Foram concebidas buscando simular a forma com que as redes neurais biológicas interagem dentro das estruturas cerebrais, sendo assim formadas por estruturas chamadas de neurônios, os quais possuem uma organização hierárquica. Cada um desses neurônios possui tarefas simples, onde o resultado obtido por cada um é combinado para formar o resultado final. Graças as suas características, as redes neurais estão aptas a resolverem problemas complexos. Isso acontece, pois as redes neurais conseguem escapar da linearidade dos sistemas, obtendo resultados através de entradas inesperadas, nunca antes vistas. As decisões são tomadas com base em sua própria estrutura, alterada no treinamento da rede. O fato de cada neurônio ser responsável por apenas uma parte da operação, faz com que as redes neurais artificiais se beneficiem de um alto nível de paralelismo e de tolerância a falhas. Isso acontece, pois as operações de múltiplos neurônios podem ser realizadas ao mesmo tempo e mesmo que um neurônio venha a falhar, existem outros sendo responsáveis pelo resultado final da operação (GURNEY, 1997).

A teoria por trás das redes neurais, teve seu inicio na publicação *(A logical calculus of the ideas immanent in nervous activity)* de Warren S. McCulloch e Walter Pitts, lançada originalmente em 1943. O sistema nervoso é uma rede de neurônios, onde cada um possui um corpo celular (*soma*) com seu núcleo e citoplasma (*pericário*), um axônio e possuem também sinapses as quais são responsáveis por ligar os neurônios entre si. Nos neurônios existe uma espécie de gatilho (*threshold*), o qual é acionado somente quando um impulso ultrapassa determinados níveis de excitação, dessa forma o sinal é propagado através das sinapses para os outros neurônios. Essa propagação de sinal é determinada pelo próprio neurônio, através dos valores gerados pela soma.

Partindo desse princípio, McCulloch e Pitts foram capazes de elaborar os princípios da neurociência computacional, os quais são largamente utilizados no aprendizado de máquina (MCCULLOCH; PITTS, 1988).

O tipo mais simples e precursor das redes neurais é o *Perceptron*, proposto por Rosenblatt em 1957. O *Perceptron* modela o funcionamento de um neurônio biológico, realizando a soma ponderada das entradas recebidas pelo neurônio com seus pesos sinápticos. Esse resultado é então enviado para uma função de ativação e caso esse resultado satisfaça as devidas condições, uma resposta positiva é enviada para a saída, caso contrário é enviada uma resposta negativa. A figura 11 ilustra um exemplo de *Perceptron*, onde os elementos com x são as entradas e os com w os seus pesos, assim como a função $ReLU$ (*Rectified Linear Unit*) de ativação do neurônio (GURNEY, 1997).

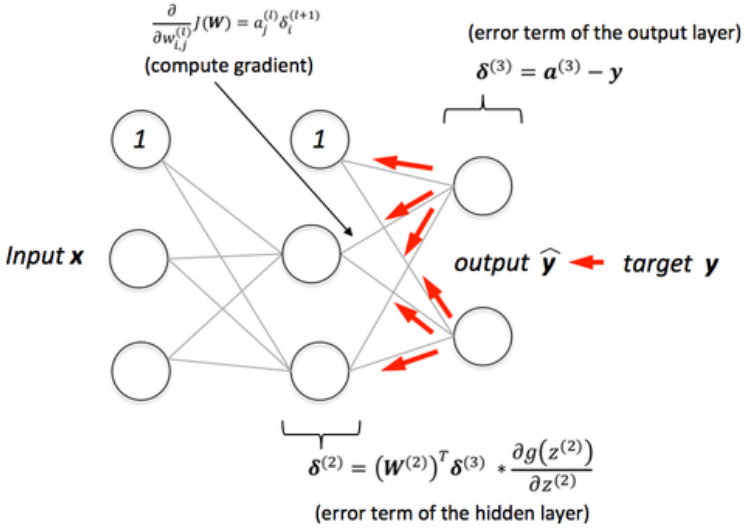
Figura 11: Perceptron



Fonte: elaborado pelo autor, adaptado de (GURNEY, 1997)

A partir do *Perceptron* foram estudadas e desenvolvidas redes neurais artificiais com estruturas mais complexas capazes de resolver problemas com maior variação de parâmetros, como é o caso das redes neurais que utilizam a abordagem de *Backpropagation* das redes neurais biológicas. Com essa técnica os erros de contribuição de cada neurônio são calculados e a derivada desse valor é utilizada para encontrar os pesos que minimizam o valor do erro. Normalmente essa é uma técnica utilizada em *Supervised Learning*, pois é necessário que a rede conheça os parâmetros que espera alcançar para assim poder calcular o erro. Um exemplo de estrutura de rede neural com *Backpropagation*, assim como as fórmulas matemáticas utilizadas na operação, podem ser vistos na figura 12 (HECHT-NIELSEN, 1992).

Figura 12: Backpropagation



Fonte: (RASCHKA, 2015)

2.3 Redes Neurais Convolucionais

As redes neurais convolucionais conhecidas também por CNNs (*Convolutional Neural Networks*) ou *Convnets*, são uma categoria de algoritmos baseada no conceito das redes neurais artificiais. Esse tipo de rede neural utiliza o método da “convolução” em pelo menos uma de suas camadas, tal metodologia é uma das mais utilizadas no *Deep Learning*, método de aprendizagem profunda baseado em múltiplos níveis de representação, obtido pela composição de módulos simples e não lineares, que transformam representações de baixo nível em representações de níveis mais altos e abstratos (LECUN; BENGIO; HINTON, 2015). Este aprendizado em profundidade é retroalimentada através das camadas, onde a saída de uma camada é a entrada da próxima, proporciona um elevado nível de extração de características, que torna essa classe de algoritmos capaz de resolver problemas considerados extremamente complexos. Devido a essa capacidade de lidar com entradas complexas, as *convnets* podem ser utilizadas para resolver os mais variados tipos de problemas, desde a identificação de objetos ou de lentes gravitacionais através de imagens, até a análise de sons distintos ou interpretação de textos contidos em documentos deteriorados (KARPATHY, 2017).

A metodologia de classificação por camadas das redes neurais convolucionais, é inspirada na metodologia que os seres humanos e alguns animais utilizam quando necessitam identificar padrões, sejam eles de forma visual ou não. Tudo isso acontece

sem que tenhamos consciência, é um processo feito pela parte inconsciente do nosso cérebro. No caso da identificação de imagens pelo cérebro humano, tudo começa quando observamos uma cena com nossos olhos e tais informações são enviadas ao nosso cérebro, que primeiro identifica as bordas contidas na imagem, em seguida suas formas primitivas, verifica as texturas dos objetos que temos interesse e assim segue em várias camadas até que um elemento com características desejadas seja encontrado em nossa memória. Somente após as operações de análise de padrões é que teremos a capacidade de dizer se o objeto é aquele ao qual temos interesse. Para que isso aconteça, os seres humanos necessitam de uma etapa de treinamento. De alguma forma nosso cérebro precisa ser treinado para descobrir o que é aquele objeto e quais são suas características, para que então em uma confrontação futura, seja capaz de acessar nas memórias algo que tenha padrões correspondentes ao objeto observado, ou pelo menos parte deles. Somente após o treinamento correto, que uma decisão com boa precisão pode ser tomada, visto que quanto mais objetos semelhantes forem estudados e observados, mais fácil será a identificação dos padrões por parte do cérebro(EAGLEMAN, 2012).

Apesar das redes neurais convolucionais serem uma excelente técnica de identificação de padrões, necessitam de um grande poder de processamento, para se tornarem aptas a identificar os padrões desejados. Isso não é algo comum apenas às redes neurais convolucionais, visto que outras técnicas que utilizam a abordagem conexionista, apresentam um elevado consumo de poder computacional. Outro problema encontrado nas *convnets* é a necessidade de uma quantidade considerável de dados para serem utilizados no treinamento, pois, dependendo do problema a ser resolvido, a obtenção de dados em larga escala é uma tarefa difícil. Um treinamento realizado com dados insuficientes irá impactar severamente no desempenho da rede, pois a qualidade dos dados obtidos assim como a modelagem correta da rede são as características que mais influenciam na obtenção de resultados coerentes, que sejam capazes de resolver os problemas propostos (ARAÚJO *et al.*, 2017).

2.3.1 Camada Convolucional

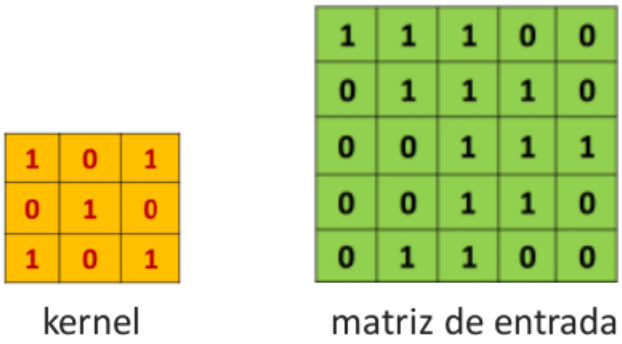
A convolução é um método matemático de processamento de sinais digitais, amplamente utilizado em diversas áreas da computação. O método da convolução é capaz de combinar dois sinais para formar um terceiro sinal. Com seu uso, é possível

estabelecer uma relação entre o sinal de entrada, o sinal de saída e o sinal de resposta. Essa relação é feita através do chamado *kernel* convolucional, esse componente é basicamente o padrão ao qual se deseja estabelecer uma ligação com o sinal de entrada e o de saída, sua representação é feita de forma numérica. Devido as suas características, as convoluções podem ser usadas nos mais diversos tipos de entradas sejam elas sons, imagens, textos ou qualquer outro tipo de sinal que possa ser representado de forma numérica (SMITH, 1999).

Tradicionalmente o *kernel* convolucional é definido de maneira estática, sendo calculado de acordo com o sistema ao qual se deseja descobrir a relação. Dessa forma, se um sistema possui variáveis muito complexas, a dificuldade de estabelecer um *kernel* para a solução é proporcional, o que acaba dificultando a aplicação das convoluções em sistemas muito complexos. Esse problema é solucionado pela utilização das redes neurais em conjunto com as convoluções. Redes neurais são excelentes ferramentas para a identificação de padrões, o *kernel* pode ser considerado um padrão que estabelece a relação entre sinais. Dessa forma é possível que as redes neurais sejam utilizadas para encontrar o *kernel*, que estabeleça a ligação entre a entrada e a saída desejada, tornando assim possível a obtenção de relações com sistemas extremamente complexos (KARPATHY, 2017).

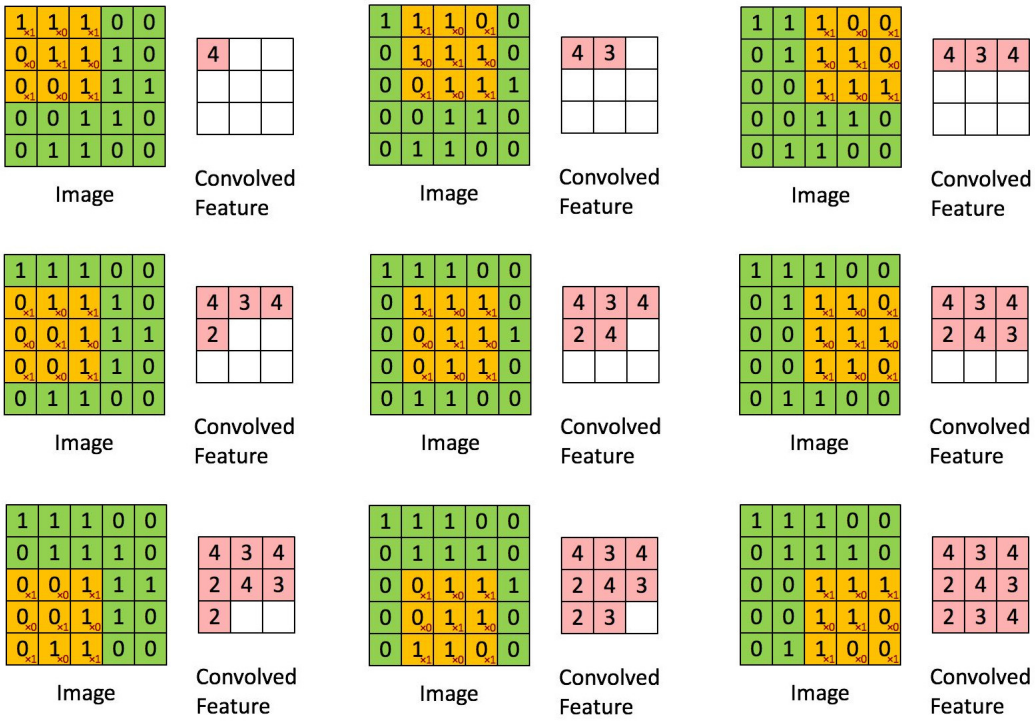
A operação convolucional acontece quando o *kernel* percorre uma matriz de entrada em toda sua extensão, essa operação é feita com o ponto central do *kernel* sendo acoplado em cada posição da matriz, onde é realizado produto escalar entre *kernel* e matriz. O resultado é armazenado em uma matriz pós convolução, conhecida por '*Activation Map*' ou '*Feature Map*', a qual contém as características extraídas da entrada com base nos padrões utilizados no *kernel*. A figura 13, ilustra um *kernel* de matriz $3x3$ e uma matriz de entrada 5x5. Já o processo de convolução utilizando os componentes da figura 13 pode ser visualizado na figura 14 onde a entrada de $5x5$, é percorrida pelo *kernel* $3x3$ (UJJWAL, 2016).

Figura 13: *Kernel* e matriz de entrada



Fonte: (UJJWAL, 2016)

Figura 14: Exemplo de Convolução



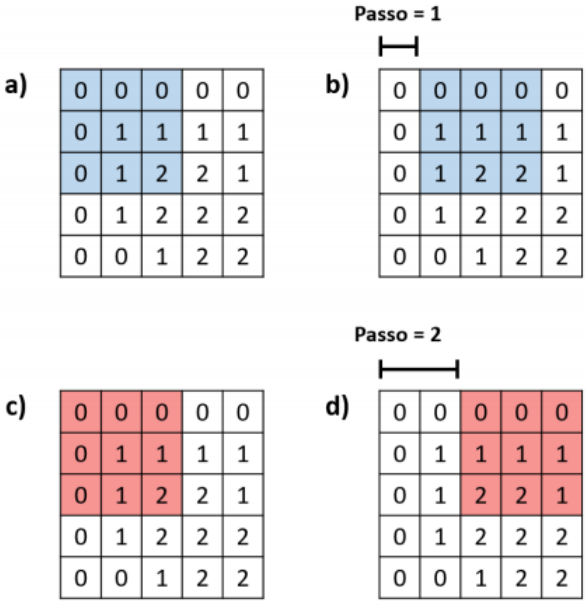
Fonte: (UJJWAL, 2016)

O *kernel* utilizado na operação convolucional geralmente é impar, pois é o pixel central que determina os posicionamentos dos novos pontos a serem definidos na matriz de resultado. O *kernel* deve também ser menor do que a imagem de entrada, para que assim consiga percorrê-la. É importante considerar que quanto maior a complexidade da entrada, maior a complexidade da convolução. No caso de imagens coloridas, por exemplo, o operador da convolução precisa percorrer a imagem em 3 dimensões, ou seja nos 3 canais de cor (*R,G,B*), resultando assim em 3 matrizes de saída, uma para cada canal. Este processo demanda muito mais poder de processamento do que

a análise feita com imagens em tons de cinza, algo que deve ser levado em conta durante o projeto da *ConvNet* (KARPATHY, 2017).

Existem 3 parâmetros que são responsáveis por controlar a operação de convolução, são eles: profundidade(*depth*); passo(*stride*) e *zero-padding*. A profundidade é igual ao número de filtros utilizados na convolução, ou seja, se este parâmetro for definido como 3, serão aplicados 3 filtros na mesma camada. Quanto maior a profundidade, mais características podem ser extraídas da entrada, mas a complexidade do processamento proporcionalmente com o ganho nas características encontradas. O atributo de passo determina qual será a precisão do *kernel* ao percorrer a matriz de entrada. Se o *padding* for 1, o *kernel* percorre pixel a pixel da matriz, se for 2, percorre um pixel e pula o seguinte, realizando novamente a operação no próximo ponto, até que a matriz seja percorrida em sua totalidade. *Zero-padding* é uma operação que preenche as bordas da matriz com 0, isso é feito quando não se deseja perder características nas bordas da entrada. Por exemplo, quando uma matriz de $5x5$ é confrontada com um *kernel* de $3x3$, suas bordas serão perdidas, pois o *kernel* deve ser posicionado totalmente dentro da matriz de entrada. Para resolver esse problema o *zero-padding* pode ser utilizado, possibilitando assim que o operador convolucional não perca as informações contidas nas bordas da matriz. A Figura 15 demonstra a alteração do parâmetro de passo na operação de convolução (ARAÚJO *et al.*, 2017).

Figura 15: *Stride*



Fonte: (ARAÚJO *et al.*, 2017)

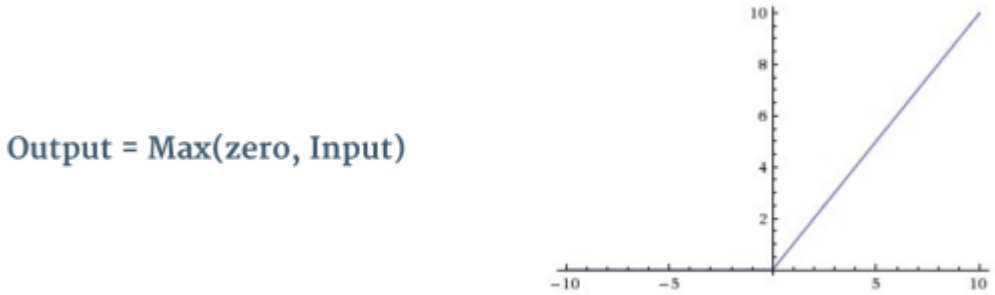
O grande feito das *ConvNets* é utilizar as técnicas de aprendizado de padrões

das redse neurais para descobrir o *kernel* convolucional, ou seja não é necessário que o *kernel* com as características desejadas seja informado, mas sim que a rede seja alimentada com uma quantidade significativa de dados que ilustrem essas características corretamente. De posse dessas informações, a própria rede neural fará os ajustes de seus pesos sinápticos e utilizará o *backpropagation* para diminuir o erro até encontrar o valor do *kernel* que mais se assemelhe ao padrão contido nas entradas de treinamento. Dessa forma, é possível descobrir as características contidas nas entradas desejadas, podendo após isso utilizar esse conhecimento para analisar outras entradas que talvez contenham tais características. Devido a isso as camadas de convolução devem ser modeladas com muito cuidado, pois são elas que proporcionam a extração das características que serão então utilizadas no decorrer da rede neural (KARPATHY, 2017).

2.3.2 Camada de Não Linearidade

Nas redes neurais convolucionais normalmente se faz presente um operador de não linearidade *(Non Linearity)*, essa estrutura geralmente é utilizada logo após as camadas de convolução. Seu uso é recomendado, pois as convoluções são operações lineares, esses resultados lineares podem limitar o desempenho da rede neural, assim como a sua capacidade de extrair as características nas camadas seguintes. Para contornar esse problema, são utilizadas funções matemáticas de não linearidade, juntamente com um valor constante, o chamado $bias$. A função mais comum é a chamada $ReLU$ (*rectified Linear Unit*), representada pela fórmula *Max(0, input)*. Esse método deixa que apenas sinais maiores que *0* passem adiante para as próximas camadas, isso faz com que somente as características realmente importantes avancem nas camadas da rede neural. Quanto maiores os valores contidos nos pontos da matriz de saída, maior a sua significância, ou seja se o valor é menor que *0* ele não é significante para as operações. O uso do $ReLU$ também diminui o custo computacional, pois se a entrada é *0* significa que o resultado da matriz naquele ponto sera *0* também, não necessitando assim que operações matemáticas complexas sejam realizadas. Além do $ReLU$ representado na figura 16, podem ser utilizadas também outras funções de não linearidade, como por exemplo a sigmoide ou $tanh$ (*hyperbolic tangent*) (UJJWAL, 2016).

Figura 16: ReLU (*Rectified Linear Unit*)

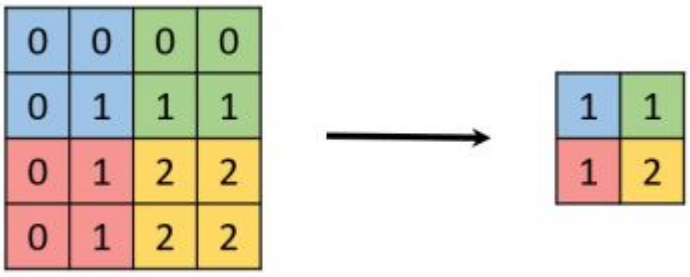


Fonte: (UJJWAL, 2016)

2.3.3 Camada de *Pooling*

O objetivo da Camada de *Pooling* é reduzir as dimensões da entrada, garantindo assim um ganho computacional nas operações subsequentes das próximas camadas da rede neural. Essa redução de dimensões é uma operação que deve ser realizada com cautela para que características importantes da entrada não sejam perdidas juntamente com a diminuição. Seu funcionamento consiste na substituição de porções da matriz por um valor correspondente, que representa a porção como um todo. Para isso podem ser utilizadas varias métricas. Normalmente é realizada uma operação de valor máximo, onde apenas o maior valor da porção de pontos selecionados é levado adiante para a próxima camada da rede, também podem ser utilizadas operações de média, mediana, entre outras (ARAÚJO *et al.*, 2017). A figura 17 ilustra a operação de ponto máximo.

Figura 17: *Pooling*



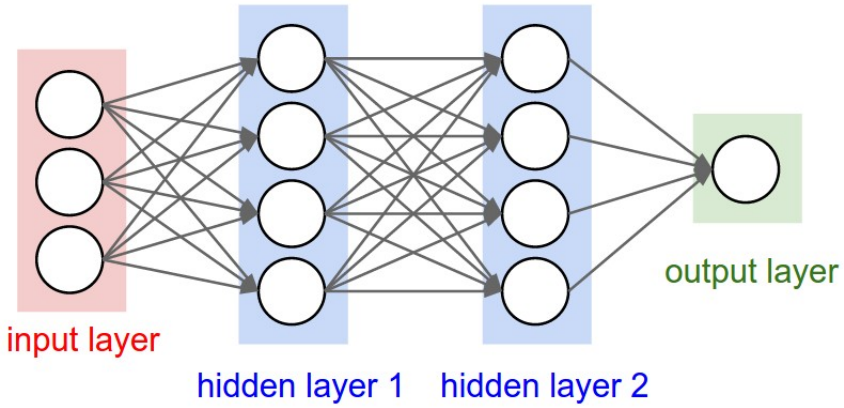
Fonte: (ARAÚJO *et al.*, 2017)

2.3.4 Camada Totalmente Conectada

As camadas totalmente conectadas são as camadas finais das *ConvNets*, que utilizam as características extraídas nas camadas anteriores para realizar a classificação da entrada em uma classe. O nome *Full-Connected* representa que todos os

neurônios dessa camada estão conectados entre si, funcionando como um *perceptron* multicamadas. Geralmente as camadas totalmente conectadas utilizam a função de ativação *SoftMax*, que realiza uma distribuição probabilística, com bases nas classes definidas, sobre os valores de entrada. Nessa camada pode ser aplicado um parâmetro chamado *dropout*, cuja função é remover aleatoriamente, a cada iteração de treinamento, uma certa porção de neurônios, devolvendo-os na próxima iteração. A remoção temporária faz com que os neurônios contidos na camada consigam distribuir melhor seus pesos sinápticos, isso acontece pois os neurônios ficam menos dependentes entre si, tendo assim uma maior contribuição nos resultados, deixando a rede neural com um maior nível de predição. A figura 18 demonstra a estrutura de uma rede neural, a qual possui 4 camadas totalmente conectadas (ARAÚJO *et al.*, 2017).

Figura 18: Camada totalmente conectada



Fonte: (KARPATHY, 2017)

2.3.5 TensorFlow

O TensorFlow constitui-se em um conjunto de ferramentas e bibliotecas de técnicas de aplicação em redes neurais. É uma API *open-source*, desenvolvida pelo *Google Brain*[4], seu propósito é facilitar o desenvolvimento de sistemas com aprendizagem profunda que utilizam redes neurais. O funcionamento da ferramenta segue o fluxo de um grafo, onde os nós do grafo representam as operações matemáticas e as arestas, *arrays* multidimensionais. Foi desenvolvido para ser flexível, podendo ser executado em múltiplas CPUs e GPUs, sendo em *desktops*, servidores ou dispositivos móveis. Um dos exemplos de utilização do TensorFlow é o sistema de indicação de vídeos do YouTube, que utiliza *deep learning* para prever vídeos de acordo com as características

[4] Divisão do Google especializada em inteligência artificial

de cada usuário, levando em consideração seu histórico de visualizações e *likes*, algo que é feito para os milhões de usuários que possuem contas cadastradas na plataforma (ABADI *et al.*, 2015).

Uma característica interessante do TensorFlow é a sua capacidade de rodar sobre GPUs, mais especificamente GPUs NVIDIA com arquitetura CUDA[5]. Esse é um fator muito importante quando se trata de processamento de dados em larga escala, visto que as GPUs são uma categoria de hardware excelente para processamento paralelo, sendo muito mais indicadas para técnicas de *machine learning* do que os processadores, devido, principalmente, as características da arquitetura das GPUs (ABADI *et al.*, 2015).

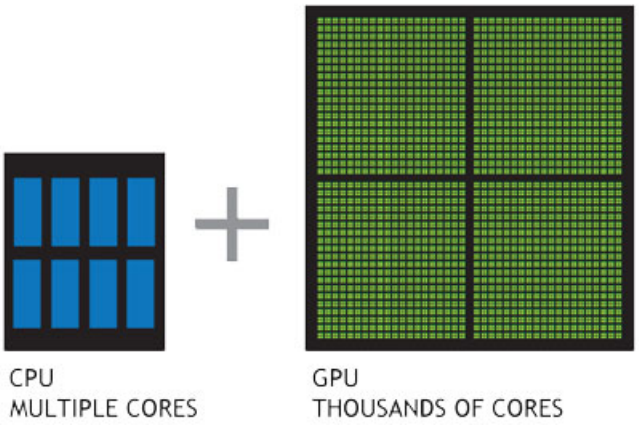
Inicialmente as GPUs foram construídas para acelerar aplicações gráficas em computadores, como no caso de reprodução de processamento de imagens e renderizações de objetos 3D. Uma GPU consegue lidar com múltiplas tarefas ao mesmo tempo, como no caso de jogos, renderizando múltiplos grupos de *pixels* ao mesmo tempo, reunindo-os em um único *frame* ao final da operação. Essa é uma característica da qual as redes neurais se beneficiam quando usadas em conjunto com GPUs, pois utilizam cálculos matriciais em larga escala, justamente o ponto forte das GPUs. Esse é um procedimento que pode ser feito sem problemas em uma CPU, porém os processadores tem seu ponto forte em operações encadeadas, conseguindo processar porções maiores, mas em menores quantidades por ciclo (BELL; GARLAND, 2008).

Para melhorar ainda mais o desempenho de software com execução paralela em GPUs, a NVIDIA desenvolveu em 2016 a arquitetura de processamento paralelo CUDA (*Compute Unified Device Architecture*). Com o seu lançamento iniciou-se uma nova perspectiva no uso de técnicas de programação GPGPU (técnica onde GPUs são utilizadas para propósito geral em aplicações científicas). A arquitetura CUDA possui bibliotecas para que códigos em C++ possam ser escritos para serem executados diretamente em GPUs NVIDIA. O grande ganho de desempenho da arquitetura CUDA acontece devido aos núcleos de cooperação *multithread*, não necessitando de transmissão em fluxo contínuo, já que os núcleos CUDA podem comunicar-se entre si. A figura 19 demonstra a comparação entre a organização dos núcleos, de um CPU e de uma GPU com a tecnologia CUDA. Com o uso de técnicas de processamento GPGPU,

[5] Arquitetura de processamento paralela desenvolvida pela NVIDIA (BELL; GARLAND, 2008).

a CPU fica responsável apenas pela parte sequencial do software enquanto a GPU lida com o elevado número de operações matemáticas envolvidas. Dessa forma a CPU tem seus processos aliviados, podendo utilizar seus ciclos para outras tarefas de elevada importância para o sistema operacional (GHORPADE *et al.*, 2012).

Figura 19: CPU x GPU



Fonte: (GHORPADE *et al.*, 2012)

Além da compatibilidade com diferentes tipos de *hardware*, o grande benefício da utilização do *TensorFlow* é a agilidade proporcionada na implementação. Com a ferramenta é possível que operações como as convoluções sejam criadas com uma simples chamada de método, sendo passados apenas os parâmetros desejados na operação. Para a criação de uma camada convolucional devem ser passados os parâmetros:

- *layer*:contém a camada anterior a convolução desejada;
- *filter*: recebe os pesos compartilhados pela CNN;
- *strides*: parâmetro onde são definidos os valores desejados de *stride*;
- *padding*: onde é definido o tipo de *padding* a ser utilizado na camada convolucional, quando é definido como "SAME", são adicionadas colunas de *pixels*, para que as informações contidas nas bordas da imagem não sejam perdidas.

A figura 20 demonstra a chamada de um método responsável por criar uma camada de convolução na rede neural.

Figura 20: Camada convolucional com TensorFlow

```
def conv2d(layer, num_input_channels, conv_filter_size, num_filters):
    weights = create_weights(shape=[conv_filter_size, conv_filter_size, num_input_channels, num_filters])
    bias = create_biases(num_filters)
    layer = tf.nn.conv2d(input=layer, filter=weights, strides=[1, 1, 1, 1], padding='SAME')
    layer += bias
    return layer
```

Fonte: (AUTOR. 2017)

2.3.6 Considerações do Capítulo

Este capítulo apresentou o referencial teórico utilizado na solução do trabalho. A contextualização das representações e características das expressões faciais humanas universais é de extrema importância, visto a necessidade da compreensão de como funcionam as expressões faciais utilizadas no projeto. O conhecimento dessas características é muito valioso para a correta modelagem das camadas necessárias, para extrair as características mais importantes de cada expressão pela rede neural convolucional.

Tratou-se também dos conceitos sobre aprendizagem de máquina e do funcionamento das redes neurais artificiais. A contextualização destes assuntos é importante devido a necessidade da compreensão das diferentes técnicas de implementação de algoritmos de inteligência artificial. Tendo foco no uso das redes neurais artificiais, metodologia escolhida para o presente trabalho, devido as suas características de aprendizado semelhantes ao ser humano, o que lhe proporciona uma incrível capacidade de solucionar problemas complexos, como por exemplo no reconhecimento de expressões faciais humanas.

Foi apresentado o funcionamento das redes neurais convolucionais (*convnets*), assim como é introduzida a principal ferramenta utilizada no projeto (TensoforFlow). O conhecimento desses aspectos é de suma importância, pois as CNNs são estruturas capazes de identificar os mais diversos tipos de padrões. Sejam eles contidos em sons, imagens, textos ou em qualquer tipo de entrada digitalizável. Já o TensorFlow proporciona as ferramentas necessárias para que uma rede neural convolucional, seja implementada de uma maneira mais direta. Dessa forma o desenvolvedor pode se focar mais no planejamento da RNA e na interpretação das características do problema, sem tanta preocupação com o funcionamento de métodos de mais baixo nível.

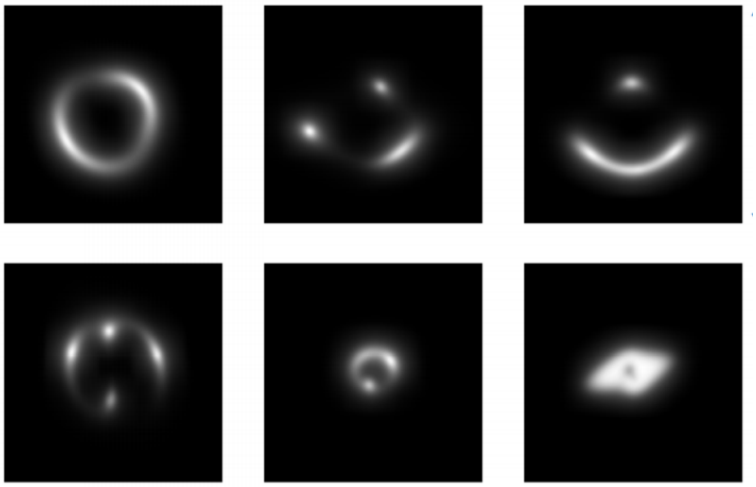
3 TRABALHOS RELACIONADOS

A identificação de padrões em imagens usando abordagens conexionistas ou estatísticas, demanda uma grande quantidade de amostras para treinamento da rede ou da técnica de aprendizagem supervisionada. Especificamente, na abordagem de redes neurais convolucionais, é necessário uma grande quantidade de amostras separadas por classes e apresentando uma qualidade aceitável para o processamento. Os trabalhos relacionados, apresentados aqui, ilustram as várias abordagens de manipulação destes *datasets*, sua catalogação ou rotulagem apropriadas. Foram levantados trabalhos sobre detecção de expressões faciais tradicionais e também sobre análise se microexpressões, a fim de constituir um estudo inicial do estado da arte neste domínio.

O trabalho desenvolvido por (PETRILLO *et al.*, 2017), demonstra a utilização de uma CNN em um caso real, onde é necessário o trabalho de pré processamento do *dataset*, pois não existem amostras suficientes para a realização de um treinamento adequado ao problema. O objetivo do trabalho é utilizar uma rede neural, para identificar objetos astronômicos chamados lentes gravitacionais. Lentes gravitacionais são formadas quando um corpo massivo posiciona-se entre um objeto e seu observador. Devido a grande massa do objeto, que pode ser desde uma galáxia até buraco negro, o tecido do espaço-tempo é distorcido e isso faz com que a luz percorra uma trajetória curvilínea. Graças a esse fenômeno, o observador é capaz de experimentar um efeito de uma lente de aumento natural, ao observar o objeto entre a lente gravitacional (PETRILLO *et al.*, 2017).

Com a evolução da tecnologia contida nos equipamentos de observação espacial, tornou-se mais fácil a obtenção de dados de alta qualidade sobre os mais variados tipos de corpos contidos no espaço. Entretanto, com um número tão elevado de dados a análise manual torna-se difícil, pois além de entradas numerosas é necessária a presença de pessoas altamente capacitadas para a classificação das amostras. Algumas imagens presentes no *dataset* utilizado no treinamento da rede, podem ser vistas na figura 21.

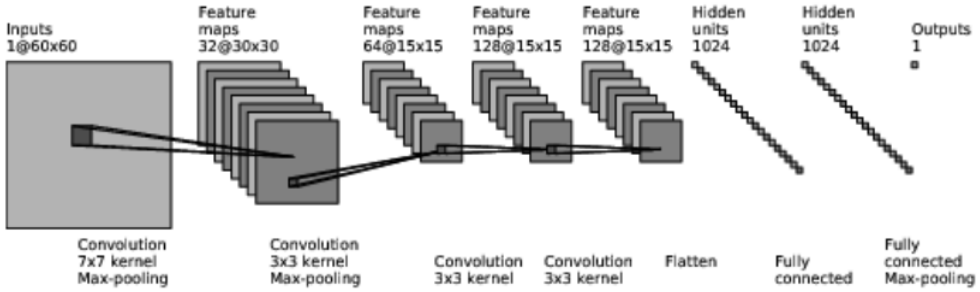
Figura 21: Amostra do *dataset* de lentes gravitacionais



Fonte: (PETRILLO *et al.*, 2017)

Para facilitar o trabalho de classificação, os autores utilizaram a metodologia das redes neurais convolucionais, para realizar a distinção entre lentes gravitacionais e outros corpos celestes. Para a etapa de treinamento os astrônomos realizaram manipulações nos dados, criando assim suas próprias representações de lentes gravitacionais baseadas nas lentes reais, isso foi necessário, pois lentes gravitacionais são entidades muito específicas e a equipe possuía apenas 657 amostras, as quais foram classificadas de forma manual por humanos, um número claramente insuficiente para a complexidade da classificação almejada. Para exemplo de objetos diferentes de lentes gravitacionais foram utilizadas imagens de galáxias, conjunto de imagens que também foi manipulado pelos astrônomos. O *dataset* completo utilizado pelos cientistas foi de 6 milhões de imagens, 3 milhões para as lentes gravitacionais e 3 milhões para as não lentes gravitacionais. Esses exemplos foram definidos com *labels* 1 e 0 respectivamente. Um número alto, mas necessário para resultados mais precisos na classificação das lentes gravitacionais. Para a identificação das lentes os cientistas optaram por utilizar o padrão *zero-padding*, visto que as informações contidas nas bordas da imagem podem representar atributos importantes. Como função de ativação no *layer* totalmente conectado foi escolhida a *sigmoid*. A estrutura da rede neural utilizada é composta de 10 camadas, as quais podem ser conferidas na figura 22.

Figura 22: Estrutura da CNN de lentes gravitacionais



Fonte: (PETRILLO *et al.*, 2017)

Após o treinamento da rede os astrônomos utilizaram 761 imagens de entrada para serem classificadas pelo algoritmo. Algo que se feito por observadores humanos, poderia apresentar um alto índice de incoerências, devido ao elevado número de amostras a serem analisadas. Com a utilização de uma rede neural convolucional os astrônomos conseguiram classificar com sucesso 56 candidatas a lentes gravitacionais. Demonstrando assim a eficácia dos métodos de aprendizagem de máquina, até mesmo, com situações de uso muito específicos, como na classificação de objetos como lentes gravitacionais (PETRILLO *et al.*, 2017).

No trabalho de (CORREA *et al.*, 2016) os autores abordam a aplicação de redes convolucionais profundas, na identificação de expressões faciais humanas através de imagens e vídeos.

Para a realização do projeto, alguns *datasets* foram testados, entre eles: *Extended Cohn Kanade (CK+); Radboud Faces Database (RaFD) e Facial Expression Recognition Challenge (FERC-2013)* (CORREA *et al.*, 2016). O *dataset* escolhido para o desenvolvimento do projeto foi o *FERC-2013*, devido a quantidade de imagens por classe e principalmente pelo fato de as expressões faciais fotografadas para o *dataset*, serem naturais e não posadas como em outros bancos de imagens disponíveis. (CORREA *et al.*, 2016).

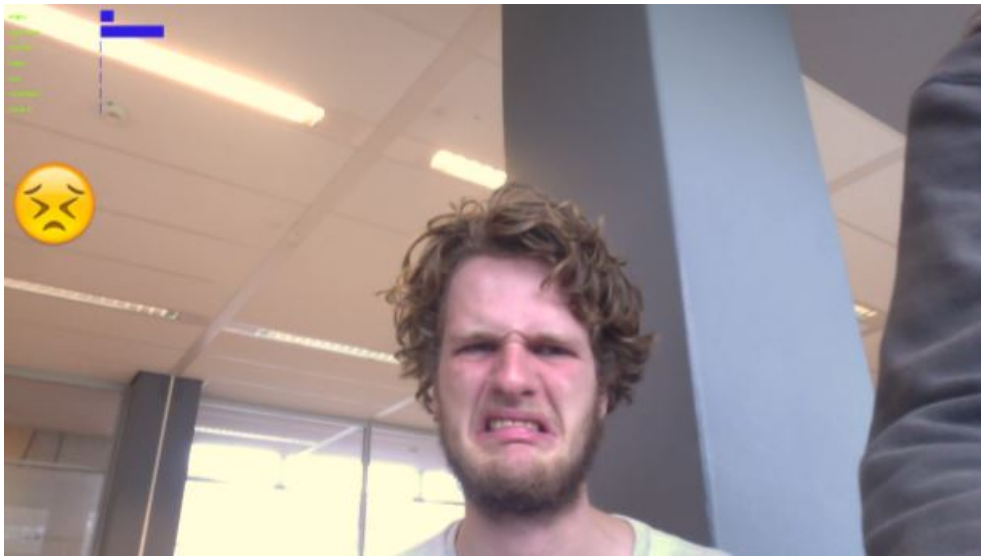
A rede neural proposta foi desenvolvida com o auxilio da biblioteca *TFLearn*, rodando na camada superior do *TensorFlow*. Essa metodologia foi escolhida para facilitar o processo de projeto da rede neural, pois não é necessário a criação manual de casa neurônio, ao invés disso são criadas camadas inteiras de neurônios. Para auxiliar no trabalho com imagens, no que diz respeito a escalonamento e identificação de rostos foi utilizado o *framework OpenCV* (CORREA *et al.*, 2016).

Após o trabalho concluído, o grupo conseguiu prever as expressões básicas,

através de imagens e vídeos com precisão de até 63%. O treinamento foi realizado utilizando 100 *epochs* e 9000 imagens do *dataset* utilizado, sendo que após 10 *epochs* os resultados já atingiram uma precisão de 60% nas previsões.

Para demonstrar o funcionamento os autores utilizaram a biblioteca OpenCV, para utilizar a webcam do computador, de forma a capturar imagens, realizar a previsão e mostrar o resultado na tela. A figura 23 demonstra o funcionamento do projeto 23.

Figura 23: Visualização da expressão em tempo real



Fonte: (CORREA *et al.*, 2016)

A abordagem utilizada pelos autores, foi capaz de convergir para um resultado correto, mesmo com poucas iterações (CORREA *et al.*, 2016). Prevendo com 63% de confiabilidade a expressão realizada pelo usuário, sendo dessa forma uma excelente arquitetura.

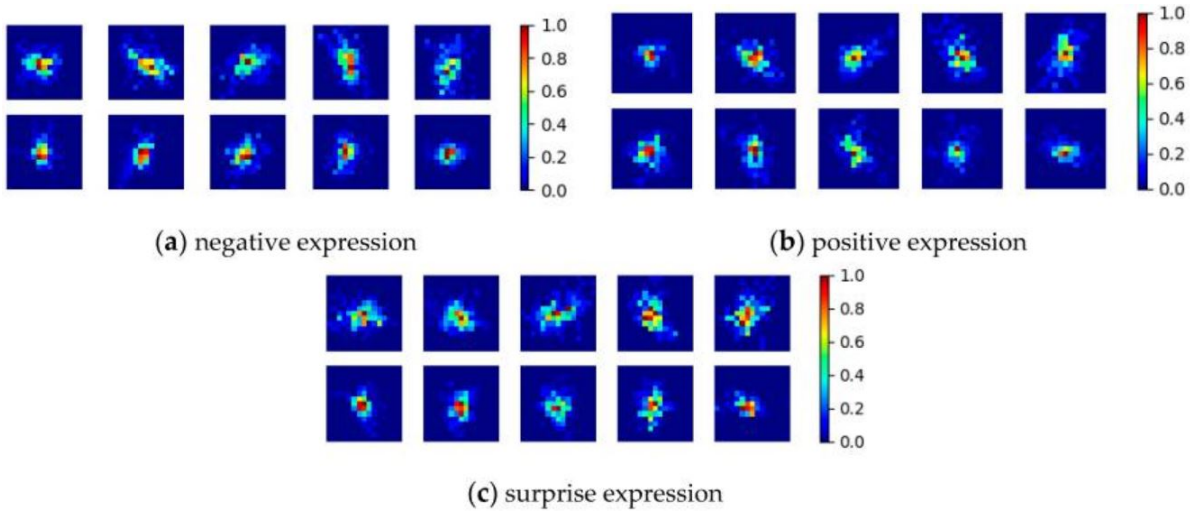
Além das macroexpressões, com a utilização da inteligência artificial, existe a possibilidade do reconhecimento das sutis microexpressões. Essa possibilidade é apresentada pelos pesquisadores romenos Diana Borza, Radu Danescu, Razvan Itu e Adrian Sergiu Darabant, através do trabalho denominado *High-Speed Video System for Micro-Expression Detection and Recognition*.

O objetivo central do trabalho realizado, é decidir se uma expressão é ou não uma microexpressão e não necessariamente classificar a emoção sentida pela pessoa. Para a realização do trabalho os pesquisadores utilizaram uma câmera capaz de filmar a 170fps a uma resolução de 2048x1088, com lentes de 9mm e um campo de visão variável entre 37º a 64º. Como microexpressões são breves e muito sutis, esse tipo de

equipamento acaba por ser uma ferramenta de elevada importância para a correta sua correta identificação (BORZA *et al.*, 2017).

Para a caracterização das microexpressões os pesquisadores utilizaram o *dataset* CASME II[1]. Esse banco de imagens, contém 247 amostras de microexpressões. Tais amostras foram analisadas através de um filtro gaussiano 2D, afim de estabelecer as regiões faciais que caracterizam as expressões (BORZA *et al.*, 2017). A figura 24, demonstra o mapa de características faciais após a utilização do filtro gaussiano.

Figura 24: Análise de expressões com filtro gaussiano 2D



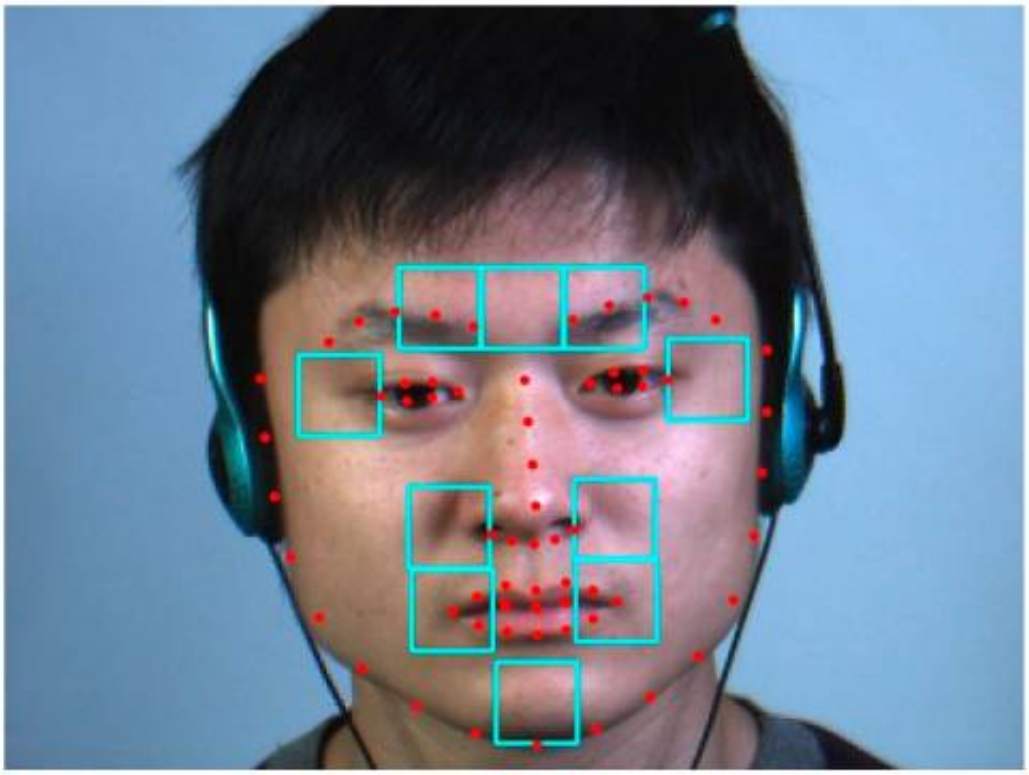
Fonte: (BORZA *et al.*, 2017)

Com o intuito de realizar a identificação das microexpressões os pesquisadores marcaram 10 pontos na face região da face, os pontos correspondem aos lugares onde ficam os músculos responsáveis pela execução das expressões faciais. As 10 regiões marcadas tem magnitude de seus movimentos analisada e após isso, é executado um algoritmo de aprendizado chamado *Adaboost*[2], o qual decide através das magnitudes aferidas se a expressão pode ser considerada uma microexpressão ou não (BORZA *et al.*, 2017). As localizações dos músculos monitorados podem podem ser vistos na figura

[1] *Dataset* de microexpressões espontâneas, capturadas a 200fps (WJ. *et al.*, 2014).

[2] Adaboost ou *adaptative boosting* é um algoritmo de aprendizado de maquina adaptável, o qual foi desenvolvido por Yoav Freund e Robert E Schapire (FREUND; SCHAPIRE, 1997).

Figura 25: Regiões dos músculos responsáveis pelas expressões faciais



Fonte: (BORZA *et al.*, 2017)

3.1 Considerações Finais

A partir destes trabalhos relacionados, verificamos a importância de como os *datasets* devem ser manipulados e de como as CNNs podem ser devidamente parametrizadas para o treinamento e aplicações.

O trabalho sobre as lentes gravitacionais objetiva, principalmente, abordar a complexidade na obtenção de uma base de dados bem catalogada, assim como a necessidade de pré-processamento com dados existentes. O projeto de reconhecimento facial utilizando redes neurais convolucionais profundas, figura como uma fonte inicial de pesquisa e inspiração para o presente trabalho, servindo como um guia de quais ferramentas e disposição de arquiteturas utilizar, para uma correta predição de expressões faciais. Por último o trabalho sobre identificação de microexpressões, mostra um pouco mais das sutilezas das características de uma microexpressão humana, reforçando a necessidade de um processamento cuidadoso e de câmeras com taxas de capturas elevadas de *frames*. Levantou-se meios necessários para a correta caracterização e representação destas expressões tão breves, assim como a importância de um *dataset* específico de microexpressões, como no caso do CASME II.

4 METODOLOGIA

Neste capítulo é exposta a metodologia científica utilizada no presente trabalho, constando a abordagem de coleta de dados, o objeto de estudo e a análise dos resultados obtidos.

A metodologia do trabalho tem o carácter exploratório, pois a proposta é a investigação sobre um determinado tema (expressões faciais e aprendizado de máquina) (LAKATOS, 2017). Como resultado busca-se a junção dos assuntos, resultando em uma protótipo funcional capaz de identificar as expressões faciais universais humanas.

Os objetos de estudo são as imagens capturadas pelo autor, as quais são identificadas pela CNN e comparadas com as características estabelecidas, pelo estudo sobre expressões faciais em (EKMAN; FRIESEN, 1975) . Dessa forma os resultados obtidos pela previsão da rede neural são validados de acordo com os aspectos conhecidos das expressões faciais.

Os processos utilizados para a identificação das imagens e a apresentação dos resultados, pode ser conferida no capítulo de desenvolvimento e experimentos.

5 DESENVOLVIMENTO E EXPERIMENTOS

Neste capitulo é apresenta-se o desenvolvimento do projeto, são também demostrados quais os passos necessários para a identificação das expressões faciais e microexpressões contidas em um vídeo, juntamente com os experimentos realizados.

A rede neural convolucional utilizada para realizar a identificação das expressões faciais está dividida em 9 camadas. A implementação da rede foi feita com a utilização da *API Tensorflow*, sendo executada no modo de GPU, onde foi utilizada uma GPU Nvidia GeForce GTX 970 para realização do processamento, tanto na fase de treinamento, quanto na identificação das expressões faciais contidas em video.

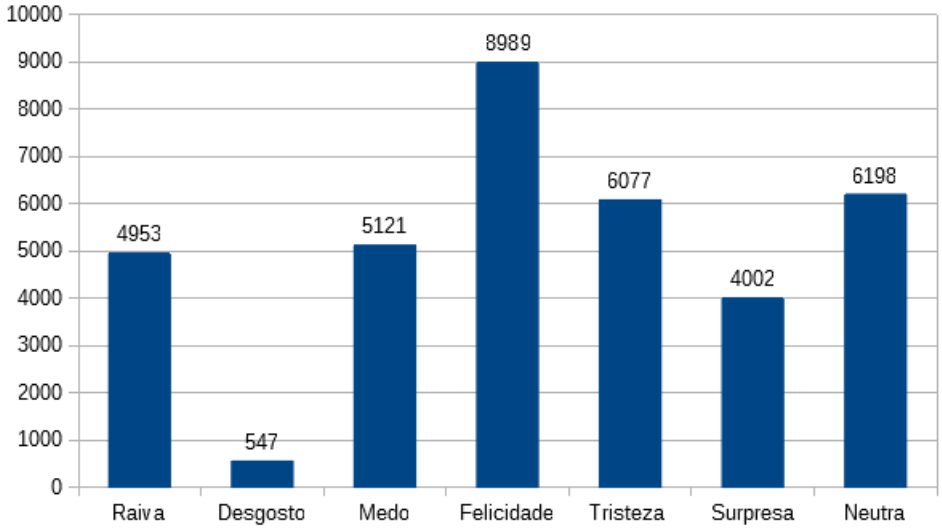
Para a realização de um treinamento satisfatório da RNA, foram necessários 100 *epochs*, algo que com o processamento realizado por uma GPU teve a duração de aproximadamente 16 horas.

5.1 *Dataset*

O *dataset* é uma das partes mais importantes quando se trata da realização preparação de uma rede neural. Visto que é necessário um grande número de amostras, as quais devem estar corretamente catalogadas. Para o treinamento da CNN utilizada no trabalho, o *dataset* utilizado foi o *Facial Expression Recognition Challenge (FERC-2013)*, disponível no site Kaggle[1]. O *dataset* foi selecionado principalmente pelo fato de que as expressões contidas, são espontâneas e não posadas, além do fato de possuir uma quantidade considerável de imagens, 35887 exemplares ao total, divididos com base nas expressões faciais universais. Na figura 26 pode ser vista a quantidade de imagens por cada classe do *dataset*.

[1] Kaggle (www.kaggle.com) é uma plataforma para competições sobre modelagem e análise preditiva usando *Datasets*, disponível para validação de modelos.

Figura 26: Distribuição de classes do *dataset*



Fonte: (AUTOR. 2018)

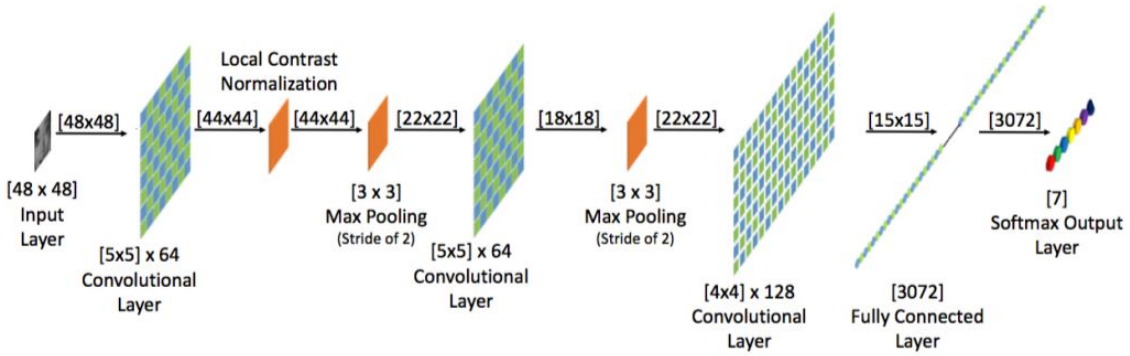
Como qualquer *Dataset*, o contexto de produção interfere bastante nos resultados modelados. Por exemplo, a figura 26 demonstra um bom conjunto de amostras, porém com significativas diferenças entre as categorias de imagens. Enquanto existem 8989 imagens da expressão de felicidade, existem apenas 547 de desgosto, um número reduzido e que prejudica de certa forma a qualidade das previsões da expressão de desgosto, por exemplo.

5.2 Estrutura da CNN

A estrutura utilizada na CNN, foi totalmente inspirada na arquitetura presente no trabalho de identificação de expressões faciais, realizado por (CORREA *et al.*, 2016). Que por sua vez é uma versão reduzida da estrutura já conhecida da *alexnet*[2]. A estrutura utilizada pode ser vista na figura 27.

[2] Trabalho que popularizou o uso das CNNs na visão computacional. Foi considerado um marco pois utilizava varias camadas convolucionais em sequência, algo que não acontecia com os outros trabalhos relacionados na época (KARPATHY, 2017)

Figura 27: Estrutura da CNN do projeto



Fonte: (CORREA *et al.*, 2016)

Com essa estrutura foi possível repetir a taxa de acerto encontrada pelo grupo que a propôs, chegando aos 63% de precisão na previsão das expressões faciais universais.

Os parâmetros detalhados de cada camada podem ser vistos na listagem a seguir:

- Input layer: recebe cada um dos frames do video a serem previstos, cuja resolução de cada uma das imagens é fixa em $48x48$ pixels.
- *Convolutional layer [5 x 5] x 64*: primeira camada de convolução da rede, onde é realizada uma convolução de $5x5$ pixels, na imagem recebida ($48x48$) da *input layer*, com o parâmetro *filters* definido como 64.
- *Local Contrast Normalization*: camada responsável por realçar o contraste da imagem, melhorando assim os contornos da face.
- *Max pooling [3 x 3]*: camada de *pooling* com tamanho definido como $3x3$ e *stride* 2.
- *Convolutional layer [5 x 5] x 64*: segunda camada de convolução da CNN, onde é realizada uma operação de convolução de $5x5$ com parâmetro de *filter* definido como 64. A operação utiliza a saída da camada de *pooling* anterior, a qual é uma imagem de tamanho $22x22$ pixels.
- *Max pooling [3 x 3]*: camada que recebe a imagem $18x18$, resultante da convolução anterior e realiza uma operação de *pooling* com tamanho e *stride*, definidos como $3x3$ e 2 respectivamente.
- *Convolutional layer [4 x 4] x 128*: última camada convolucional, recebe como entrada uma imagem de resolução $22x22$, onde é realizada uma convolução de

tamanho $4x4$, com *filter* deinifido como 128.

- *Dropout*: responsável por diminuir o *overfiting*[3] no treinamento da CNN, isso é feito com a retirada parcial de alguns neurônios da rede.
- *Fully Connected Layer*: camada totalmente conectada da CNN, é composta por 3072 neurônios totalmente conectados, sua entrada é uma imagem $15x15$, resultando da camada anterior de convolução.
- *Softmax Output Layer*: etapa final da rede neural, onde são definidos os resultados de similaridade da imagem processada, com base em cada uma das 7 classes de expressões as quais a rede foi preparada para identificar.

Na imagem 28, podo ser conferido o método responsável por fazer a montagem das camadas da rede no projeto.

Figura 28: Método de criação da CNN do projeto

```
def build_network(self):
    self.network = input_data(shape=[None, 48, 48, 1])
    self.network = conv_2d(self.network, 64, 5, activation='relu')
    self.network = local_response_normalization(self.network)
    self.network = max_pool_2d(self.network, 3, strides=2)
    self.network = conv_2d(self.network, 64, 5, activation='relu')
    self.network = max_pool_2d(self.network, 3, strides=2)
    self.network = conv_2d(self.network, 128, 4, activation='relu')
    self.network = dropout(self.network, 0.3)
    self.network = fully_connected(self.network, 3072, activation='relu')
    self.network = fully_connected(
        self.network, len(EMOTIONS), activation='softmax')
    self.network = regression(
        self.network,
        optimizer='momentum',
        loss='categorical_crossentropy'
    )
    self.model = tflearn.DNN(
        self.network,
        checkpoint_path=SAVE_DIRECTORY + '/emotion_recognition',
        max_checkpoints=1,
        tensorboard_verbose=2
    )
    self.load_model()
```

Fonte: (AUTOR, 2018)

[3] O *overfiting* acontece, quando o modelo se ajusta de forma satisfatória, entretanto não consegue ser suficientemente eficaz na predição das entradas (KARPATHY, 2017).

5.3 Captura de imagens

Assim como o *dataset*, a captura das imagens utilizadas para a realização da previsão da CNN, tem uma elevada importância na correta detecção do padrão da expressão facial. Para a captura das imagens, foi utilizada a *action cam* Yi Cam, a qual possui como principais parâmetros: ângulo de visualização de $155°$; abertura $F2.8$ e distância focal de $2,77mm$. A câmera foi escolhida para a realização do projeto devido a sua capacidade de capturar até $240fps$ (*frames per second*), uma taxa relativamente alta, se comparada a maioria das câmeras que operam na faixa de 30 a $60fps$. Para realizar a captura dessa quantidade de *frames* a câmera acaba tendo que sacrificar um pouco da sensibilidade a luz no vídeo e da resolução, caindo para $848x480$. Apesar desse empecilho, a maior taxa de captura é de extrema importância, quando se trata da tarefa de identificar expressões e microexpressões, pois elas podem acontecer de maneira muito rápida e sútil. Dessa forma é válido a troca da resolução pela taxa de *frames*, pois se capturado a uma taxa baixa de, mudanças ocorridas na face podem passar despercebidas. A *Yi Cam* pode ser vista na figura 29.

Figura 29: Yi Cam



Fonte: (AUTOR. 2018)

5.4 Implementação

A implementação do processo de identificação de expressões é dividida em duas partes, sendo a primeira a captura das imagens e a segunda, o armazenamento do *log* contendo as expressões identificadas, separadas por conjuntos de *frames*. Em

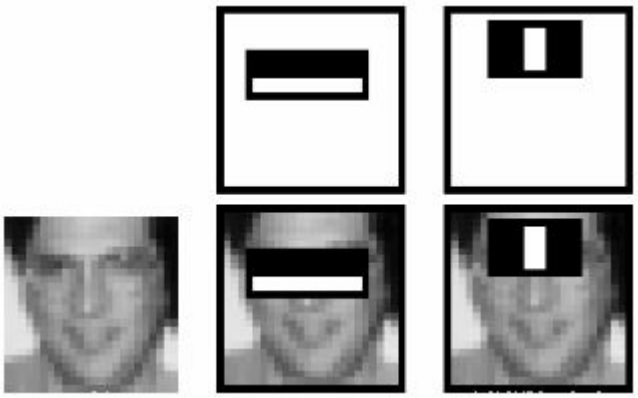
algumas das etapas contidas no processo, são necessárias manipulações nos *frames*. Para a realização das etapas de pré-processamento de imagens e de *feedback* visual, foi utilizado o $OpenCV$[4], a qual possui ferramentas prontas para o escalonamento e identificação de faces, assim como uma série de outros recursos para trabalhos com imagens. Todos os códigos utilizados no desenvolvimento do trabalho, podem ser conferidos no repositório git, hospedado no link (https://Tinhoso@bitbucket.org/Tinhoso/tcc).

5.4.1 Escalonamento e identificação facial

Como visto na sessão de estrutura da CNN, a rede neural necessidade que suas entradas sejam imagens com resolução de $48x48$ pixels (mesma resolução utilizada nas imagens do *dataset*). Dessa forma para uma correta previsão, é necessário o pré-processamento das imagens. Nessa etapa é realizado o escalonamento dos *frames*, os quais estão na resolução de $848x480$, para a resolução esperada pela rede, que é de $48x48$. Porém antes do escalonamento da imagem para o tamanho correto, é necessária a identificação do rosto humano, sem essa etapa a rede neural seria obrigada a tentar identificar uma expressão facial em uma imagem contendo diversos outros objetos, os quais aumentariam a complexidade do reconhecimento. O método de reconhecimento facial utilizado no projeto, é chamado *Haar Cascade*, o qual pode ser facilmente implementado com o uso do $OpenCV$. Para identificar a face, o método utiliza matrizes de características dos principais componentes do rosto humano, essas matrizes são então comparadas com a imagem desejada. Se a face é encontrada, então o método retorna a posição do rosto na imagem (OPENCV, 2018a). A essência do funcionamento do método pode ser vista na figura 30.

[4] Biblioteca de código livre para computação visual, fornece várias funções para manipulação e processamento de imagens(OPENCV, 2018b)

Figura 30: Haar Cascade



Fonte: (OPENCV, 2018a)

O Haar Cascade é um método capaz de identificar faces de forma rápida, sem um uso computacional extremo. Entretanto ele possui uma certa limitação, o rosto a ser identificado, deve ter um bom enquadramento na imagem, se estiver muito inclinado a identificação se torna difícil ou impossível em certos casos.

5.4.2 Identificação de expressões e microexpressões

Após a identificação do rosto e escalonamento do *frame*, a CNN tem tudo o que precisa para realizar a identificação da expressão contida na face. Entretanto, como visto anteriormente, uma expressão facial é algo complexo e em certas vezes diferenças sutis não significam necessariamente uma mudança de expressão. Devido a isso e a utilização de um video a $240 fps$, foi utilizada uma abordagem média entre as previsões, que confere mais confiabilidade aos resultados obtidos.

As imagens recebidas pela rede neural são reunidas em grupos de 3, onde a previsão é realizada normalmente, em cada uma das imagens. O resultado é devolvido na forma de um vetor de 7 posições, onde cada posição contém um número que varia de 0 até 1, representando a probabilidade da imagem identificada pertencer aos grupos de expressões determinados. Um vetor de uma imagem identificada contendo a expressão de surpresa, com cada uma de suas posições descritas, pode ser visto como exemplo na figura 31.

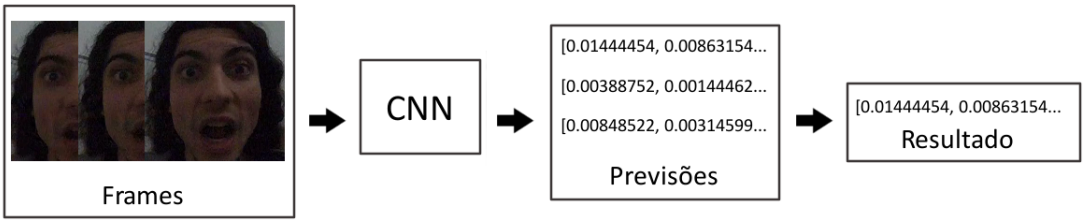
Figura 31: Vetor de expressões

Raiva Nojo Medo Alegria Tristeza Surpresa Neutra
[0.01444454, 0.00863154, 0.03748007, 0.01920675, 0.02570196, 0.80059499, 0.09394012]

Fonte: (AUTOR. 2018)

Após as 3 previsões serem completadas, é realizado uma média aritmética entre as posições dos vetores que contém os resultados de cada *frame* recebido pela RNA. Dessa forma são reduzidos os ruídos na identificação de certas expressões faciais, pois é necessária uma alteração um pouco mais significativa nos componentes do rosto, do que apenas uma alteração na iluminação ou no ângulo da face, para caracterizar uma mudança de expressão facial. O fluxo do resultado da previsão e da operação de média, pode ser conferido na figura 32.

Figura 32: Identificação das expressões



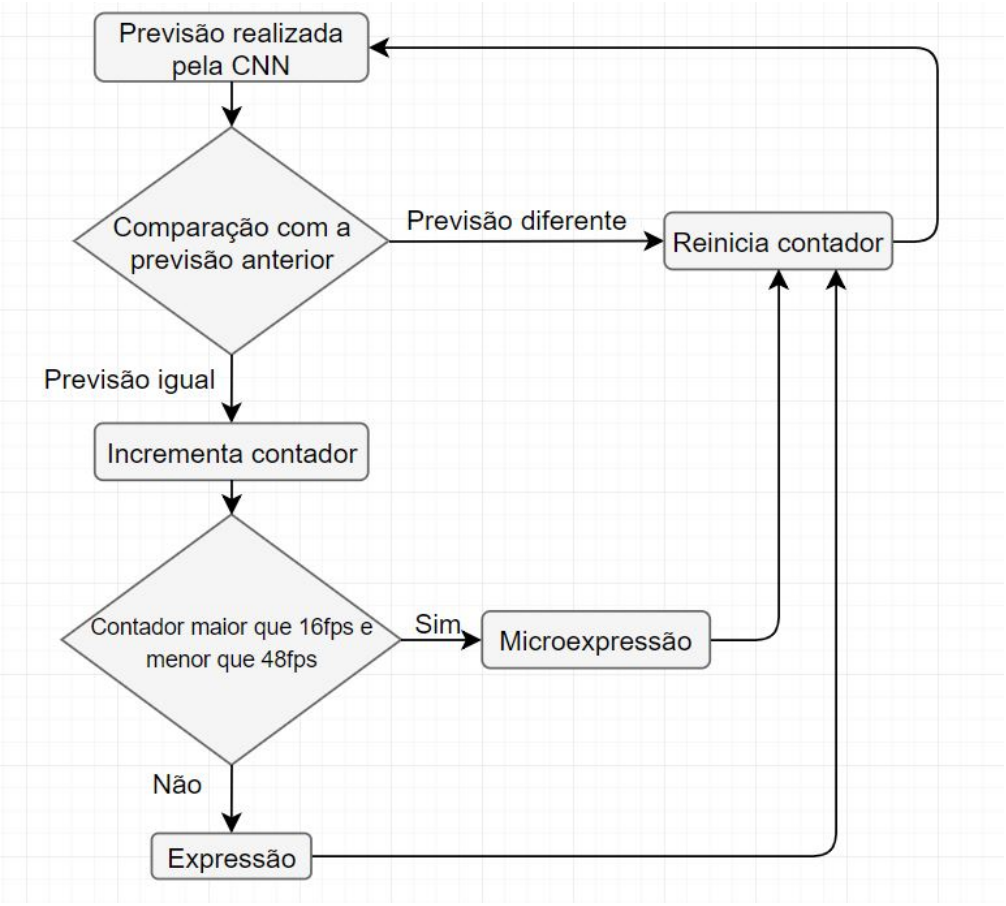
Fonte: (AUTOR. 2018)

Para a identificação das microexpressões, o método utilizado foi a da realização da contagem de duração da expressão, isso foi feito através dos *frames* do video. Como a captura das imagens é realizada a $240fps$, basta que o tempo de duração das microexpressões seja multiplicado pela quantidade de imagens capturadas por segundo. Dessa forma, com uma taxa de captura em $240fps$, uma microexpressão tem a duração definida entre $16fps$ e $48fps$.

De posse das informações de duração em *frames* das microexpressões, basta então que cada grupo já previsto pela rede, seja comparado com a anterior e, se apresentarem o mesmo resultado de identificação, significa que a expressão facial foi mantida nesse intervalo. Ou seja, se uma expressão permanecer a mesma entre o intervalo de $16fps$ à $48fps$, pode ser considerada uma microexpressão, mas, se a duração for maior do que os $48fps$, é então considerada uma expressão normal.

A implementação da identificação de microexpressões foi realizada utilizando um contador de *frames*, quando a previsão mantem-se igual a anterior o contador é incrementado, caso contrário, é então reiniciado. Como a previsão compõe-se de um vetor de 7 posições, é escolhida a posição mais significativa para fins de comparação. Como por exemplo, na expressão de surpresa o valor mais significativo é o da posição de número 6 do vetor[5], esse valor então será utilizado como correspondente à expressão de surpresa, sendo adotado para comparações com as outras previsões. Um fluxograma explicando a implementação pode ser visto na figura 33 e o trecho de código, responsável pela diferenciação entre macroexpressões e microexpressões, pode ser conferido na figura 34.

Figura 33: Fluxograma da identificação de microexpressões



Fonte: (AUTOR. 2018)

[5] As posições correspondentes a cada expressão podem ser vistas na figura 31.

Figura 34: Código de classificação das microexpressões

```
if len(micro_array) > 0:
    index = master_counter - 1
    expression_msg = index2expression(micro_array[master_counter])
    if micro_array[index] == micro_array[master_counter]:
        micro_counter += 1
    else:
        #verificação das sequências de expressões
        if micro_counter > minfps_micro and micro_counter < maxfps_micro:
            flag_me = True #flag das microexpressões
            print ("Microexpressão:", expression_msg, "- Frame:", frame_counter)
            expression_log.append("Microexpressão: " + str(expression_msg) + " - Frame: " + str(frame_counter))
        micro_counter = 0
    print ("Macroexpressão:", expression_msg, "- Frame:", frame_counter)
    expression_log.append("Macroexpressão: " + str(expression_msg) + " - Frame: " + str(frame_counter))
```

Fonte: (AUTOR. 2018)

5.5 Apresentação dos resultados

A previsão das expressões e das microexpressões é representada visualmente durante o processamento do video. Quando uma expressão é identificada, são exibidas barras representado a probabilidade de ocorrência de cada expressão, as quais podem ser vistas no canto esquerdo superior da tela e logo abaixo uma figurinha faz a representação da expressão de forma caricata. Quando uma microexpressão é reconhecida, um aviso é emitido no video, este aviso tem a duração de 10 *frames* e pode ser visto em letras vermelhas contendo a letra M(microexpressão), no canto superior direito da tela, juntamente com o número correspondente do vetor de característica (1 = raiva, 2 = nojo, 3 = medo ,4 = alegria ,5 = tristeza ,6 = surpresa ,7 = neutra). A distribuição dos componentes pode ser vista na figura 35.

Figura 35: Identificação em video



Fonte: (AUTOR. 2018)

Além da representação gráfica da identificação das expressões e microexpressões, é gerado um *log* em arquivo de texto, contendo todas as expressões identificadas durante o video, juntamente com o contador dos *frames* agrupados contendo as expressões. Um exemplo de *log* pode ser visualizado na figura 36.

Figura 36: *Log*

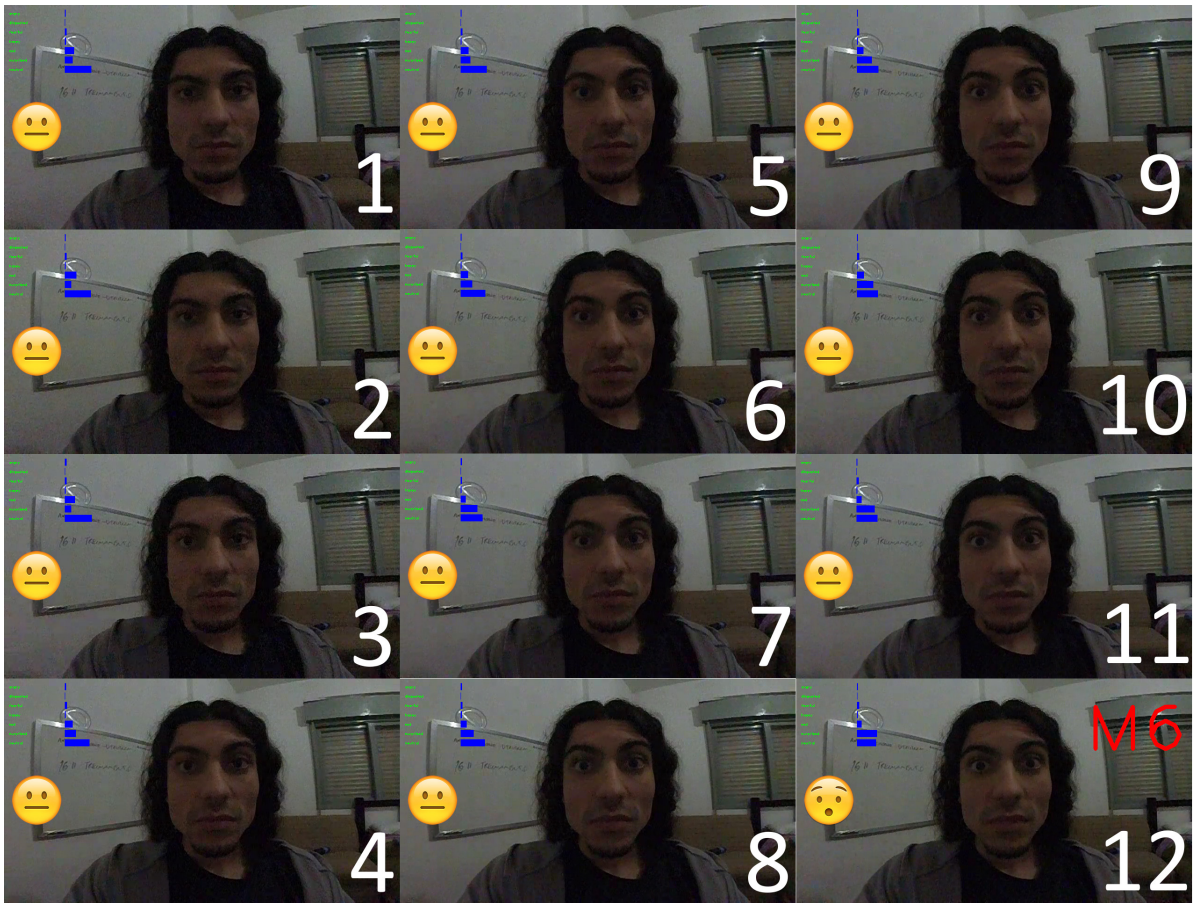
```
1   Macroexpressão: Neutra - Frame: 3
2   Macroexpressão: Neutra - Frame: 6
3   Macroexpressão: Neutra - Frame: 9
4   Macroexpressão: Neutra - Frame: 12
5   Macroexpressão: Neutra - Frame: 15
6   Macroexpressão: Neutra - Frame: 18
7   Macroexpressão: Neutra - Frame: 21
8   Macroexpressão: Neutra - Frame: 24
9   Macroexpressão: Neutra - Frame: 27
10  Macroexpressão: Neutra - Frame: 30
11  Macroexpressão: Neutra - Frame: 33
12  Macroexpressão: Neutra - Frame: 36
13  Macroexpressão: Neutra - Frame: 39
14  Microexpressão: Tristeza - Frame: 42
```

Fonte: (AUTOR. 2018)

5.6 Experimentos

Para demonstrar o funcionamento do projeto foram executados dois experimentos distintos, uma previsão de microexpressões, no quesito de tempo e o outro na identificação de macroexpressões em diferentes faces. Para o teste de microexpressão, foi utilizado um vídeo contendo a troca rápida de uma expressão neutra para uma de surpresa, toda a ação durou apenas 36 *frames*, o que representa $240fps$, equivalente à $0,15segundos$. A figura 37 mostra a sequência de imagens das expressões realizadas. Vale salientar que os números em branco nos *frames*, servem apenas para indicar a ordem de leitura e não estão presentes na implementação.

Figura 37: Previsão da microexpressão



Fonte: (AUTOR. 2018)

Como vista na figura 37, a mudança da expressão neutra para a de surpresa foi reconhecida com sucesso pelo software. Essa afirmação tem base nos resultados obtidos de maneira numérica, representados na tabela 1 e nos fundamentos de identificação de expressões faciais, estabelecidos por (EKMAN; FRIESEN, 1975). As características mais importantes para serem observadas na mudança de expressão, são

as sobrancelhas, que assumem uma postura mais alta conforme o passar do tempo, assim como os olhos, que ficam totalmente abertos, sinais esses que demonstram a acentuação da expressão de surpresa.

Tabela 1: Resultados do experimento de microexpressão

Frame	R(%)	No(%)	Me(%)	F(%)	T(%)	S(%)	Ne(%)
1	2	1	4	3	18	15	57
2	2	1	4	3	23	10	57
3	4	1	4	2	19	11	59
4	4	1	4	2	13	17	59
5	4	1	5	4	12	15	59
6	4	1	5	4	10	17	59
7	2	1	2	1	9	33	52
8	2	1	4	2	9	26	56
9	3	1	6	2	12	26	50
10	2	1	5	1	13	30	48
11	2	1	5	1	11	35	45
12	2	1	3	1	7	46	40

Raiva = R; Nojo = No; Medo = M; Felicidade = F; Tristeza = T; Surpresa = S; Neutra = Ne.
Fonte: (AUTOR. 2018)

Para o experimento de identificação de macroexpressões, foram realizados testes com 3 participantes voluntários, os quais executaram algumas das expressões faciais universais. Esse experimento foi realizado para atestar o funcionamento da CNN, na identificação de padrões faciais, mesmo com faces contendo características distintas entre si. Os testes podem ser conferidos nas figuras 38, 39 e 40.

Figura 38: Teste de macroexpressão 1



Expressões: alegria, neutra, tristeza
Fonte: (AUTOR. 2018)

Figura 39: Teste de macroexpressão 2



Expressões: surpresa, neutra, tristeza
Fonte: (AUTOR. 2018)

Figura 40: Teste de macroexpressão 3



Expressões: alegria, neutra, tristeza
Fonte: (AUTOR. 2018)

É interessante de ser observado, que a CNN conseguiu identificar as macroexpressões faciais dos participantes do teste, mesmo com obstruções e oclusões, como óculos e a presença de barba e cabelos compridos. Os resultados representados de maneira numérica, podem ser conferidos na tabela 2.

Tabela 2: Resultados dos experimentos de macroexpressões

Teste - frame	R(%)	No(%)	Me(%)	F(%)	T(%)	S(%)	Ne(%)
Macroexpressão 1 - 1	1	1	1	93	1	1	2
Macroexpressão 1 - 2	7	1	2	1	15	1	73
Macroexpressão 1 - 3	5	1	3	1	65	1	24
Macroexpressão 2 - 1	1	1	1	1	1	79	16
Macroexpressão 2 - 2	8	2	4	2	5	5	74
Macroexpressão 2 - 3	21	6	9	8	48	1	7
Macroexpressão 3 - 1	1	2	1	79	4	1	12
Macroexpressão 3 - 2	1	1	1	1	17	1	78
Macroexpressão 3 - 3	1	1	1	1	90	1	5

Raiva = R; Nojo = No; Medo = M; Felicidade = F; Tristeza = T; Surpresa = S; Neutra = Ne.
Fonte: (AUTOR. 2018)

A identificação das macroexpressões pode ser comprovada através dos resultados de previsão obtidos pela CNN, pois ao confrontar as imagens testadas, com as

características de cada expressão, descritas no trabalho *unmasking the face - 1975*. O percentual de maior valor condiz com a expressão identificada pelos quesitos descritos no livro, o que corrobora com a funcionalidade do protótipo.

5.7 Considerações Finais

O uso de uma CNN como componente identificador de expressões provou-se uma boa escolha, entretanto encontrar o *dataset* correto foi um desafio, já que muitos bancos de imagens não tem qualidade e quantidade suficiente de expressões faciais e, além disso alguns *datasets* não são liberados ao público, ou são pagos e de difícil acesso.

O treinamento mesmo sendo executado em uma GPU teve um tempo consideravelmente longo $(16h)$, se o trabalho exigisse a completa implementação de uma nova arquitetura da rede, teria sido necessárias muitas horas de trabalho envolvidas na etapa de planejamento e teste, até a obtenção de bons resultados. Algo que deixaria os requisitos de tempo, de desenvolvimento do projeto inviáveis. Dessa forma surgiu a opção da utilização de uma arquitetura funcional e já conhecida, que proporcionou mais tempo, para o desenvolvimento da metodologia e modelagem para o reconhecimento das microexpressões em seu quesito de tempo, através da análise de vídeos com alta amostragem de *frame rate*.

6 CONCLUSÃO

Com base na pesquisa e no desenvolvimento realizados ao longo do trabalho, puderam ser percebidas as peculiaridades e características das expressões faciais humanas, assim como a compreensão das diferenças básicas entre macroexpressões e microexpressões.

Juntamente com o estudo de expressões faciais, foi realizada uma pesquisa das principais técnicas de *machine learning*, baseado no aprendizado supervisionado, utilizando redes neurais convolucionais. A partir dessa pesquisa observa-se o embasamento teórico necessário, para a compreensão do funcionamento de uma CNN. Algo extremamente necessário para o objetivo central do trabalho, identificar expressões faciais humanas de forma automatizada.

Durante o projeto verificou-se, a possibilidade da identificação de expressões faciais universais humanas e da diferenciação de macroexpressões e microexpressões com base no tempo. O uso da CNN como ferramenta para a identificação dos padrões de expressões faciais, provou-se excelente, pois conseguiu identificar as expressões em diferentes tipos de rostos, mesmo com a presença de particularidades, como barba, óculos e cabelos distintos entre si.

As expressões faciais humanas podem conter diversas informações, algumas que dizem respeito ao estado emocional das pessoas, seus desejos e características. Esse tipo de conhecimento, pode ser utilizado para fins de diagnóstico de doenças silenciosas, como a depressão e a ansiedade. Sendo dessa forma uma característica interessante, a ser analisada na identificação de problemas psíquicos.

Quanto a trabalhos futuros, uma possibilidade seria a de sanar as limitações de identificação facial do *haar cascade*. Isso pode ser feito, com a utilização de redes neurais, dessa forma um rosto pode ser reconhecido sob diferentes ângulos. Além disso, a metodologia aplicada no trabalho, poderia ser embarcada em um agente móvel, o qual identificaria pessoas que estão passando por problemas. O agente então tentaria ajudar a pessoa de algumas formas, variando desde alegrá-las com um simples video, até prestar socorro em uma emergência.

Aliar a inteligência artificial ao diagnóstico de doenças, é um ponto que pode trazer diversas melhorias na qualidade de vida dos seres humanos, pois um problema, às vezes difícil de ser verificado em exames tradicionais, pode ser reconhecido de

forma precoce. Quando se trata de expressões faciais, compreender melhor o seu funcionamento, é algo que pode significar um importante ponto na interpretação de mensagens não verbais, as quais podem servir também como uma maneira para entendermos melhor nossos semelhantes e a nós mesmos.

REFERÊNCIAS

ABADI, M. *et al.* **TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems**. 2015. Software available from tensorflow.org. Disponível em: <https://static.googleusercontent.com/media/research.google.com/en//pubs/archive/45166.pdf>.

ARAÚJO, F. *et al.* Redes neurais convolucionais com tensorflow: Teoria e prática. **Artigos e Minicursos**, Escola Regional de Informática do Piauí, v. 1, n. 1, p. 382–406, 2017.

BASMAJIAN, J.; LUCA, C. D. **Muscles Alive: Their Functions Revealed by Electromyography**. Williams & Wilkins, 1985. ISBN 9780683004144. Disponível em: <https://books.google.com.br/books?id=H9pqAAAAMAAJ>.

BELL, N.; GARLAND, M. **Efficient Sparse Matrix-Vector Multiplication on CUDA**. [S.l.], 2008.

BORZA, D. *et al.* High-speed video system for micro-expression detection and recognition. **Sensors**, v. 17, n. 12, 2017. ISSN 1424-8220. Disponível em: <http://www.mdpi.com/1424-8220/17/12/2913>.

CASSIN, B.; RUBIN, M. **Dictionary of Eye Terminology**. Triad Pub., 2006. ISBN 9780937404683. Disponível em: <https://books.google.com.br/books?id=3XKpPwAACAAJ>.

CORREA, E. *et al.* **Emotion Recognition using Deep Convolutional Neural Networks**. [s.n.], 2016. Disponível em: <https://github.com/isseu/emotion-recognition-neural-networks/blob/master/paper/Report_NN.pdf>.

EAGLEMAN, D. **Incógnito: as vidas secretas do cérebro**. Rio de Janeiro: Rocco, 2012.

EKMAN, P. Facial expression and emotion. **American Psychologist**, American Psychologist, v. 48, p. 384–392, 1993.

EKMAN, P.; FRIESEN, W. V. **Unmasking the face: A guide to recognizing emotions from facial clues**. Oxford: Prentice-Hall, 1975.

FREITAS-MAGALHÃES, A. **Facial Action Coding System - Manual de Codificação Científica da Face Humana**. Escrytos|Ed. Autor, 2016. ISBN 9789898766113. Disponível em: <https://books.google.com.br/books?id=Al6nCwAAQBAJ>.

FREUND, Y.; SCHAPIRE, R. E. A decision-theoretic generalization of on-line learning and an application to boosting. **J. Comput. Syst. Sci.**, Academic Press, Inc., Orlando, FL, USA, v. 55, n. 1, p. 119–139, ago. 1997. ISSN 0022-0000. Disponível em: <http://dx.doi.org/10.1006/jcss.1997.1504>.

GHORPADE, J. *et al.* GPGPU processing in CUDA architecture. **CoRR**, abs/1202.4347, 2012. Disponível em: <http://arxiv.org/abs/1202.4347>.

GURNEY, K. **An Introduction to Neural Networks**. Bristol, PA, USA: Taylor & Francis, Inc., 1997. ISBN 1857286731.

HECHT-NIELSEN, R. Neural networks for perception (vol. 2). In: WECHSLER, H. (Ed.). Orlando, FL, USA: Harcourt Brace & Co., 1992. cap. Theory of the Backpropagation Neural Network, p. 65–93. ISBN 0-12-741252-2. Disponível em: <http://dl.acm.org/citation.cfm?id=140639.140643>.

KARPATHY, A. Convolutional neural networks. 2017. <http://cs231n.github.io/convolutional-networks/>; accessed 12-Setembro-2017.

LAKATOS, E. **Fundamentos de metodologia científica (8a. ed.).** Grupo Gen - Atlas, 2017. ISBN 9788597010763. Disponível em: <https://books.google.com.br/books?id=34nOtAEACAAJ>.

LANGLEY, P. The changing science of machine learning. **Machine Learning**, v. 82, n. 3, p. 275–279, Mar 2011. ISSN 1573-0565. Disponível em: <https://doi.org/10.1007/s10994-011-5242-y>.

LECUN, Y.; BENGIO, Y.; HINTON, G. E. Deep learning. **Nature**, v. 521, n. 7553, p. 436–444, 2015. Disponível em: <https://doi.org/10.1038/nature14539>.

LUGER, G. F. **Artificial Intelligence: Structures and Strategies for Complex Problem Solving**. 6th. ed. USA: Addison-Wesley Publishing Company, 2008. ISBN 0321545893, 9780321545893.

MCCULLOCH, W. S.; PITTS, W. Neurocomputing: Foundations of research. In: ANDERSON, J. A.; ROSENFELD, E. (Ed.). Cambridge, MA, USA: MIT Press, 1988. cap. A Logical Calculus of the Ideas Immanent in Nervous Activity, p. 15–27. ISBN 0-262-01097-6. Disponível em: <http://dl.acm.org/citation.cfm?id=65669.104377>.

MITCHELL, T. M. **Machine Learning**. 1. ed. New York, NY, USA: McGraw-Hill, Inc., 1997. ISBN 0070428077, 9780070428072.

MøLLER, M. F. A scaled conjugate gradient algorithm for fast supervised learning. **Neural Networks**, v. 6, n. 4, p. 525 – 533, 1993. ISSN 0893-6080. Disponível em: <http://www.sciencedirect.com/science/article/pii/S0893608005800565>.

OPENCV. Open CV face detection using haar cascades. 2018. Accessado em: 2018-06-17. Disponível em: <https://docs.opencv.org/3.4.1/d7/d8b/tutorial_py_face_detection.html>.

OPENCV. Open CV open source computer vision library. 2018. Accessado em: 2018-06-17. Disponível em: <https://opencv.org/>.

PETRILLO, C. E. *et al.* Finding strong gravitational lenses in the kilo degree survey with convolutional neural networks. **Monthly Notices of the Royal Astronomical Society**, v. 472, n. 1, p. 1129–1150, 2017. Disponível em: <+http://dx.doi.org/10.1093/mnras/stx2052>.

RAMACHANDRAN, V. **Encyclopedia of Human Behavior**. Academic Press, 1994. (Encyclopedia of Human Behavior, v. 3). ISBN 9780122269233. Disponível em: <https://books.google.com.br/books?id=St5GAAAAMAAJ>.

RASCHKA, S. Can you give a visual explanation for the back propagation algorithm for neural networks? Nov 2015. Disponível em: <https://github.com/rasbt/python-machine-learning-book/blob/master/faq/visual-backpropagation.md>.

RUSSELL, S.; NORVIG, P. **Artificial Intelligence: A Modern Approach**. 3rd. ed. Upper Saddle River, NJ, USA: Prentice Hall Press, 2009. ISBN 0136042597, 9780136042594.

SANGER, T. D. Optimal unsupervised learning in a single-layer linear feedforward neural network. **Neural Networks**, v. 2, n. 6, p. 459 – 473, 1989. ISSN 0893-6080. Disponível em: <http://www.sciencedirect.com/science/article/pii/0893608089900440>.

SMITH, S. W. **The Scientist and Engineer's Guide to Digital Signal Processing**. San Diego, California: California Technical Publishing, 1999.

SUTTON, R. S.; BARTO, A. G. **Reinforcement Learning : An Introduction**. [S.l.]: MIT Press, 1998.

UJJWAL, K. An intuitive explanation of convolutional neural networks. 2016. <https://ujjwalkarn.me/2016/08/11/intuitive-explanation-convnets/>; accessed 16-Setembro-2017.

WHO. Depression and other common mental disorders global health estimates. **Mental health**, World Health Organization, 2017. Disponível em: <http://apps.who.int/iris/handle/10665/254610>.

WITTEN, I. H.; FRANK, E.; HALL, M. A. **Data Mining: Practical Machine Learning Tools and Techniques**. 3rd. ed. San Francisco, CA, USA: Morgan Kaufmann Publishers Inc., 2011. ISBN 0123748569, 9780123748560.

WJ., Y. *et al.* Casme ii: An improved spontaneous micro-expression database and the baseline evaluation. **PLoS ONE**, v. 9, n. 1, p. e86041, 2014. Disponível em: <http://www.plosone.org/article/info%3Adoi%2F10.1371%2Fjournal.pone.0086041>.

ZHU, X. Semi-supervised learning. In: ____. **Encyclopedia of Machine Learning**. Boston, MA: Springer US, 2010. p. 892–897. ISBN 978-0-387-30164-8. Disponível em: <https://doi.org/10.1007/978-0-387-30164-8_749>.